

# Notes of Introducing to linear algebra

FrankZhou-jun\*


2019 年 12 月 14 日

## 1 the Geometry of linear equations

书上对常见的解线性方程组方式解释的很清楚了，这里从另一个角度解释”线性方程组”的意义。  
假设一个两行的线性方程组

$$\begin{aligned} 2x - y &= 0 \\ -x + 2y &= 3 \end{aligned} \tag{1}$$

① 这是一个简单的二维线性方程组，解等于  $x = 1, y = 2$ ，在行图像 中为二维空间下两条连线的交点。




② 下面考虑列图像，化简方程组：

$$x \begin{bmatrix} 2 \\ -1 \end{bmatrix} + y \begin{bmatrix} -1 \\ 2 \end{bmatrix} = \begin{bmatrix} 0 \\ 3 \end{bmatrix} \tag{2}$$

列图像中的集合意义就是找到合适的  $x$ 、 $y$ ，进行伸缩变换，然后组合列向量，得到等号右边的列向量。

---

\*研究方向：信号处理，机械故障诊断，深度学习，强化学习，邮箱:zhoujun14@yeah.net



从图中可以看到，第一列向量不变，第二列向量延伸两倍，在进行列向量组合，可以得到最右边的列向量，即可得到解  $x = 1, y = 2$ 。

$$\mathbf{A} = \begin{bmatrix} 2 & -1 \\ -1 & 2 \end{bmatrix}$$

$$\mathbf{b} = \begin{bmatrix} 0 \\ 3 \end{bmatrix}$$

由此，我们可以从中得到启发，求解线性方程组的问题其实就在问：是否最右边的所有列向量可以用列向量组合的形式进行表示？。Can I solve  $\mathbf{A}\mathbf{x} = \mathbf{b}$  for every  $\mathbf{b}$ ? ( $\mathbf{A}$  为奇异或非奇异矩阵？是否所有列向量独立)

## 2 elimination with matrix

假设增广矩阵  $(R(\mathbf{A}|\mathbf{b}))$  如下：

$$\begin{bmatrix} 1 & 2 & 1 & 2 \\ 3 & 8 & 1 & 12 \\ 0 & 4 & 1 & 2 \end{bmatrix} \xrightarrow{\text{row}_1 * -3 + \text{row}_2} \begin{bmatrix} 1 & 2 & 1 & 2 \\ 0 & 2 & -2 & 6 \\ 0 & 4 & 1 & 2 \end{bmatrix} \xrightarrow{\text{row}_2 * -2 + \text{row}_3} \begin{bmatrix} 1 & 2 & 1 & 2 \\ 0 & 2 & -2 & 6 \\ 0 & 0 & 2 & -10 \end{bmatrix}$$

其实可以使用初等矩阵进行行操作。 $\text{row}_1 * -3 + \text{row}_2$  行操作可以表示为

$$\begin{bmatrix} 1 & 0 & 0 \\ -3 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 2 & 1 & 2 \\ 3 & 8 & 1 & 12 \\ 0 & 4 & 1 & 2 \end{bmatrix} = \begin{bmatrix} 1 & 2 & 1 & 2 \\ 0 & 2 & -2 & 6 \\ 0 & 4 & 1 & 2 \end{bmatrix}$$

在该矩阵左边乘以一个矩阵是对其进行行操作，右乘是进行列操作。下面举一个例子来说明这两种操作，置换矩阵如下所示：

左乘

$$\begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix} \begin{bmatrix} a & b \\ c & d \end{bmatrix} = \begin{bmatrix} c & d \\ a & b \end{bmatrix}$$

右乘

$$\begin{bmatrix} a & b \\ c & d \end{bmatrix} \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix} = \begin{bmatrix} b & a \\ d & c \end{bmatrix}$$

### 3 multiplication and inverse matrix

#### 3.1 multiplication

##### 3.1.1 A\*列=列

$$\begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{bmatrix} \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1p} \\ a_{21} & a_{22} & \cdots & a_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{np} \end{bmatrix} = \begin{bmatrix} c_{11} & c_{12} & \cdots & c_{1p} \\ c_{21} & c_{22} & \cdots & c_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ c_{m1} & c_{m2} & \cdots & c_{mp} \end{bmatrix}$$

$A : m \times n \quad B : n \times p \quad = \quad c : m \times p$

两个矩阵相乘，可以把其中一个矩阵 B 看做多个列向量组合，将矩阵 A 每一行矩阵 B 中的某列向量，则得到矩阵 C 中对应列向量，”columns of C are combinations of columns of A”，矩阵 C 中的列向量是矩阵 A 中列向量的线性组合。这样便把前面的线性方程组结合起来思考。

##### 3.1.2 行\*B=行

下面是矩阵 A 中每一行乘以 B 得到 C 中每一行。

$$\begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{bmatrix} \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1p} \\ a_{21} & a_{22} & \cdots & a_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{np} \end{bmatrix} = \begin{bmatrix} c_{11} & c_{12} & \cdots & c_{1p} \\ c_{21} & c_{22} & \cdots & c_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ c_{m1} & c_{m2} & \cdots & c_{mp} \end{bmatrix}$$

$A : m \times n \quad B : n \times p \quad = \quad c : m \times p$

#### 3.2 inverse matrix

谈到可逆矩阵，不得不提一下奇异矩阵和非奇异矩阵，非奇异矩阵可逆，奇异矩阵不可逆。

假设矩阵 A

$$\begin{bmatrix} 1 & 3 \\ 2 & 6 \end{bmatrix}$$

很明显，经过化简后矩阵 A

$$\begin{bmatrix} 1 & 3 \\ 0 & 0 \end{bmatrix}$$

下面说明什么是奇异矩阵，若

$$\mathbf{A}x = 0 \tag{3}$$

存在任一个非零解 x，则 A 为奇异矩阵；若解 x 只有唯一零解，则是非奇异矩阵，即矩阵满秩。显然存在一个非零解  $\vec{x} = [-3, 1]$ 。

求可逆矩阵方法有 Gauss-Jordan elimination,  $\mathbf{E}[\mathbf{A} \quad \mathbf{I}] = [\mathbf{I} \quad \mathbf{A}^{-1}]$ , 注意这里就用到了”矩阵乘以列向量等于列向量”思想。E 表示对矩阵  $[\mathbf{A} \quad \mathbf{I}]$  进行行变换，若初等矩阵 E 满足  $\mathbf{EA} = \mathbf{I}$ , 则初等矩阵 E 为  $\mathbf{A}^{-1}$ , 所以  $\mathbf{EI} = \mathbf{A}^{-1}$ 。

### 4 Fractorization into A = LU

L 代表 lower 下三角，U 代表 upper 上三角

$$\mathbf{E}_{32}\mathbf{E}_{31}\mathbf{E}_{21} = \mathbf{U}$$

$$\mathbf{A} = \mathbf{E}_{21}^{-1}\mathbf{E}_{31}^{-1}\mathbf{E}_{32}^{-1}\mathbf{U}$$

$$\mathbf{L} = \mathbf{E}_{21}^{-1}\mathbf{E}_{31}^{-1}\mathbf{E}_{32}^{-1}$$

$\mathbf{L}$  计算简单，包含了消元乘数信息。下面举个例子来说明这一过程，假设已知初等矩阵

$$\mathbf{E}_{32} = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & -5 & 1 \end{bmatrix}$$

$$\mathbf{E}_{21} = \begin{bmatrix} 1 & 0 & 0 \\ -2 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

$$\mathbf{E} = \mathbf{E}_{32} \times \mathbf{E}_{21} = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & -5 & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 \\ -2 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} = \begin{bmatrix} 1 & 0 & 0 \\ -2 & 1 & 0 \\ 10 & -5 & 1 \end{bmatrix}$$

可以看到这里对消元乘数进行了相乘操作

$$\mathbf{E}_{21}^{-1} = \begin{bmatrix} 1 & 0 & 0 \\ 2 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} \quad \mathbf{E}_{32}^{-1} = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 5 & 1 \end{bmatrix}$$

$$\mathbf{L} = \mathbf{E}_{21}^{-1} \mathbf{E}_{32}^{-1} = \begin{bmatrix} 1 & 0 & 0 \\ 2 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 5 & 1 \end{bmatrix} = \begin{bmatrix} 1 & 0 & 0 \\ 2 & 1 & 0 \\ 0 & 5 & 1 \end{bmatrix}$$

可以发现这里是直接向消元乘数直接写入  $\mathbf{L}$  中。

## 5 Transposes Permutations Spaces $\mathbf{A}^n$

置换矩阵  $\mathbf{P}$ : identify matrix with reordered rows,  $\mathbf{P}^T \mathbf{P} = \mathbf{I}, \mathbf{P}^T = \mathbf{P}^{-1}$ 。

转置矩阵 Transpose 的表达式为：

$$(\mathbf{A}^T)_{ij} = \mathbf{A}_{ji} \quad (4)$$

将转置用到一个矩阵上，具有如下现象：一个矩阵转置后的矩阵等于转置前的矩阵，我们称该矩阵为 symmetric matrix，即：

$$\mathbf{A}^T = \mathbf{A} \quad (5)$$

转置有一个非常重要的作用，矩阵  $\mathbf{R}^T \mathbf{R}$  是一个对称矩阵，通过计算分析可以验证：

$$\mathbf{R} = \begin{bmatrix} 1 & 2 & 4 \\ 3 & 3 & 1 \end{bmatrix}$$


$$\mathbf{R}^T \mathbf{R} = \begin{bmatrix} 1 & 3 \\ 2 & 3 \\ 4 & 1 \end{bmatrix} \begin{bmatrix} 1 & 2 & 4 \\ 3 & 3 & 1 \end{bmatrix} = \begin{bmatrix} 10 & 11 & 7 \\ 11 & 13 & 11 \\ 7 & 11 & 17 \end{bmatrix}$$

可以发现因为  $(\mathbf{A}^T)_{ij} = \mathbf{A}_{ji}$ ，所以在相乘的过程中具有重复的运算，比如  $row_1 * col_2 = row_2 * row_1$ ，也就是右斜向上的数值关于主元线对称相等。

证明  $\mathbf{R}^T \mathbf{R}$  是一个对称矩阵  $(\mathbf{R}^T \mathbf{R})^T = \mathbf{R}^T (\mathbf{R}^T)^T = \mathbf{R}^T \mathbf{R}$

## 5.1 Spaces of $\mathbf{R}^n$

$\mathbf{R}^2$  表示的是 all 2-dim real vectors, 也就是组成的 X-Y plane。  $\begin{bmatrix} 3 \\ 2 \end{bmatrix}$ ,  $\begin{bmatrix} 0 \\ 0 \end{bmatrix}$ ,  $\begin{bmatrix} \pi \\ e \end{bmatrix}$ 。



$\mathbf{R}^2$  包含了实数组成的所有 2-dim 向量, 同理,  $\mathbf{R}^3$  包含了实数组成的所有 3-dim 向量。线性空间满足那 8 个 rules, 具有封闭性, 下面举个例子说明一下: 不是线性空间。




图 1: 取第一象限

可以验证, 虽然第一象限的点满足加法法则, 但当第一象限的点乘以一个负数时, 得到的数很明显超出了第一象限。不具有封闭特点。

下面考虑一下什么是子空间, 或者说 a vector space inside  $\mathbf{R}^2$




图 2: 子空间


可以看到这里有两条线，其中一条线穿过原点，可以验证穿过原点的这条线的所有点可构成  $\mathbf{R}_2$  下的子空间，这条线满足八个 rules，线性封闭。若果这条线不通过原点，则该线上的点乘 0 后，得到的点不在该空间范围内，也就是线性不封闭。可以得到  $\mathbf{R}^2$  的子空间：

- all of  $\mathbf{R}_2$  , 即该空间本身 是一个子空间
- any line through origin, 通过原点的线 可以是一个子空间
- zero vector only, 只有原点向量的空间

同理我们可以得到  $\mathbf{R}^3$  的子空间：

1. all of  $\mathbf{R}_3$  , 即该空间本身 是一个子空间
2. any plane through origin, 通过原点的平面 可以是一个子空间
3. any plane through origin, 通过原点的线 可以是一个子空间, 注意: 这里的线是在三维空间中, 有 3 个 component。
4. zero vector only, 只有原点向量的空间

下面讲一下矩阵的列空间：



矩阵  $\mathbf{A} = \begin{bmatrix} 1 & 3 \\ 2 & 3 \\ 4 & 1 \end{bmatrix}$ , 则  $\text{col1} = \begin{bmatrix} 1 \\ 2 \\ 4 \end{bmatrix}$  和  $\text{col2} = \begin{bmatrix} 3 \\ 3 \\ 1 \end{bmatrix}$  则 col1 和 col2 线性组合的所有向量构成  $\mathbf{R}^3$  的子空间，叫做列空间，可以是多列线性组合构成的线性空间。

## 6 Column Space and Null Space

### 6.1 Column Space

上一节已经讲了什么是列空间，这里在回顾一下，假设  $\mathbf{P}$  和  $\mathbf{L}$  是  $\mathbf{A}$  的列空间。其中  $\mathbf{P}$  是  $\mathbf{R}^3$  中的平面子空间，其中  $\mathbf{L}$  是  $\mathbf{R}^3$  中的线子空间。

$\mathbf{P} \cup \mathbf{L}$  is a subspace?

$\mathbf{P} \cap \mathbf{L}$  is a subspace?

可以确定  $\mathbf{P} \cap \mathbf{L}$  is a subspace!，因为他们交集产生的子空间在  $\mathbf{P}$  or  $\mathbf{L}$  or both 之中，所以交集一定是子空间。并集不是，不满足加法定理！

提到列空间有啥作用呢，我的理解是方便研究及知识传播，如要使线性方程组有解

$$\mathbf{A}x = b \quad (6)$$

b 应该存在  $\mathbf{A}$  的列空间中 in  $\mathbf{R}^4$

$$\mathbf{A} = \begin{bmatrix} 1 & 1 & 2 \\ 2 & 1 & 3 \\ 3 & 1 & 4 \\ 4 & 1 & 5 \end{bmatrix}$$

可以看到矩阵  $\mathbf{A}$  中  $col_3 = col_1 + col_2$ ，这说明在  $\mathbf{A}$  的列空间中，仅使用  $col_1$  和  $col_2$  就可以做子空间的基，而  $col_3$  没有做贡献，子空间可以描述为: a two dimensional subspace of  $\mathbf{R}^4$

### 6.2 Null Space

零空间是指  $\mathbf{A}x = 0$  的解形成的空间，可以发现  $x = [0 \ 0 \ 0]$  为齐次方程的解，在  $\mathbf{A} = \begin{bmatrix} 1 & 1 & 2 \\ 2 & 1 & 3 \\ 3 & 1 & 4 \\ 4 & 1 & 5 \end{bmatrix}$  很明显还有另一

个非零解  $x = [1 \ 1 \ -1]$ ，所以  $x = k[1 \ 1 \ -1]$ ，与前面的零解满足 8 个 rules，线性封闭构成零空间，即该其次方程中的零解为  $\mathbf{R}^3$  空间中的一条过原点的线。

## 7 solving $\mathbf{A}x=0$ pivots variables, special solutions

主要还是用到了 Gauss-Jordan 消元法，如矩阵  $\mathbf{A} = \begin{bmatrix} 1 & 2 & 2 & 2 \\ 2 & 4 & 6 & 8 \\ 3 & 6 & 8 & 10 \end{bmatrix}$ ，分别化简到 U(echelon) 形式、R 形式 (reduce

row echelon)

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & 2 & 2 \\ 2 & 4 & 6 & 8 \\ 3 & 6 & 8 & 10 \end{bmatrix} \quad \mathbf{A}x = 0 \quad = \quad \begin{bmatrix} 1 & 2 & 2 & 2 \\ 0 & 0 & 2 & 4 \\ 0 & 0 & 0 & 0 \end{bmatrix} \quad \mathbf{U}x = 0 \quad = \quad \begin{bmatrix} 1 & 2 & 0 & -2 \\ 0 & 0 & 1 & 2 \\ 0 & 0 & 0 & 0 \end{bmatrix} \quad \mathbf{R}x = 0$$

matlab 中可以通过 `rref(A)` 直接得到  $\mathbf{U}$  形式的矩阵，但 matlab 中的计算是这样的，将  $\mathbf{R}$  的列进行变换，pivots

columns 和 Free columns 移动到一起。

$$\begin{bmatrix} 1 & 2 & 0 & -2 \\ 0 & 0 & 1 & 2 \\ 0 & 0 & 0 & 0 \end{bmatrix} \Rightarrow \begin{bmatrix} 1 & 0 & 2 & -2 \\ 0 & 1 & 0 & 2 \\ 0 & 0 & 0 & 0 \end{bmatrix}$$

*pivotcolumn   freecolumn   pivotscolumn   freecolumn*                      *pivotcolumn   pivotscolumn   freecolumn   freecolumn*

$$\mathbf{I} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}, \mathbf{F} = \begin{bmatrix} 2 & -2 \\ 0 & 2 \end{bmatrix}, \text{ 所以 } \mathbf{R} \text{ 可以表示为 } \mathbf{R} = \begin{bmatrix} \mathbf{I} & \mathbf{F} \\ \mathbf{0} & \mathbf{0} \end{bmatrix}$$

$$\text{则 } \mathbf{R}\mathbf{x} = \mathbf{0}, \begin{bmatrix} \mathbf{I} & \mathbf{F} \\ \mathbf{0} & \mathbf{0} \end{bmatrix} x = \mathbf{0} \text{ 解得 } x = \begin{bmatrix} -\mathbf{F} \\ \mathbf{I} \end{bmatrix} = \begin{bmatrix} -2 & 2 \\ 0 & -2 \\ 1 & 0 \\ 0 & 1 \end{bmatrix}$$

这里主元列的个数  $r$  等于矩阵的秩  $r(\mathbf{A})$ , 自由列的个数等于  $n-r$ , 自由列的意思可以自由取值, 所以一旦出现自由列, 就有无穷多个解, 如何表示这些无穷多个解呢?, 找到解的基就行啦, 零空间的基一定是线性无关了, 这里自由

列的个数为 2, 则取  $[x_2, x_4] = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$ , 得到的解分别为  $k_1 \begin{bmatrix} -2 \\ 1 \\ 0 \\ 0 \end{bmatrix}, k_2 \begin{bmatrix} 2 \\ 0 \\ -2 \\ 1 \end{bmatrix}$ 。可以看到与 matlab 中  $\text{null}(\mathbf{A})$  得到

解一样。

## 8 Solving $\mathbf{Ax} = b$ Row Reduced Form $\mathbf{R}$

由前面可知, 要使  $\mathbf{Ax} = b$  有解, 则  $b$  应该在列空间  $C(\mathbf{A})$  中, 也就是  $b$  可以用矩阵  $\mathbf{A}$  各列进行线性组合表示。通过矩阵  $\mathbf{A}$  的秩可以确定解的个数。

to  $\mathbf{Ax} = b$

1.  $\text{rank}(\mathbf{A})=m=n$

$\mathbf{R} = \mathbf{I}$  1 solution

2.  $\text{rank}(\mathbf{A})=n<m$

$\mathbf{R} = \begin{bmatrix} \mathbf{I} \\ \mathbf{0} \end{bmatrix}$ , 0 or 1 solution

3.  $\text{rank}(\mathbf{A})=m<n$

$\mathbf{R} = \begin{bmatrix} \mathbf{I} & \mathbf{F} \end{bmatrix}$ ,  $\infty$  solution

4.  $\text{rank}(\mathbf{A})<m, r<n$

$\mathbf{R} = \begin{bmatrix} \mathbf{I} & \mathbf{F} \\ \mathbf{0} & \mathbf{0} \end{bmatrix}$ , 0 or  $\infty$  solution

下面使用一个具体的例子求解  $\mathbf{Ax} = b, \mathbf{A} = \begin{bmatrix} 1 & 2 & 2 & 2 \\ 2 & 4 & 6 & 8 \\ 3 & 6 & 8 & 10 \end{bmatrix}, \mathbf{b} = \begin{bmatrix} 1 \\ 5 \\ 6 \end{bmatrix}$ 。

$$\mathbf{A} : b = \begin{bmatrix} 1 & 2 & 2 & 2 & b_1 \\ 2 & 4 & 6 & 8 & b_2 \\ 3 & 6 & 8 & 10 & b_3 \end{bmatrix} = \begin{bmatrix} 1 & 2 & 2 & 2 & b_1 \\ 0 & 0 & 2 & 4 & b_2 - 2b_1 \\ 0 & 0 & 2 & 4 & b_3 - 3b_1 \end{bmatrix} = \begin{bmatrix} 1 & 2 & 2 & 2 & b_1 \\ 0 & 0 & 2 & 4 & b_2 - 2b_1 \\ 0 & 0 & 0 & 0 & b_3 - b_2 - b_1 \end{bmatrix}$$



求解  $\mathbf{Ax} = \mathbf{b}$  等于求  $x_{special}$  特解 +  $x_{null}$  零空间。特解的求法解释设置自由变量为零，在代入线性方程组求解。

$$\mathbf{R} = \begin{bmatrix} 1 & 2 & 2 & 2 & b_1 \\ 0 & 0 & 2 & 4 & b_2 - 2b_1 \\ 0 & 0 & 0 & 0 & b_3 - b_2 - b_1 \\ pivot & free & pivot & free & ? \end{bmatrix}$$

所以  $[x_2, x_4] = [0, 0]^T$ ,

$$x_1 + 2x_2 = 12x_3 = 3$$

$$\text{特解为 } x_{special} = \begin{bmatrix} -2 \\ 0 \\ 3/2 \\ 0 \end{bmatrix}, \text{ 上一节求出的零解为 } x_n = k_1 \begin{bmatrix} -2 \\ 1 \\ 0 \\ 0 \end{bmatrix} + k_2 \begin{bmatrix} 2 \\ 0 \\ -2 \\ 1 \end{bmatrix}, x = x_{special} + x_n, \text{ 在二维空间内,}$$

$\mathbf{Ax} = \mathbf{b}$  的解为：零空间内某一向量 + 特解向量。

## 9 Independent, Basis, and, Dimension

repeat, when  $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$  are columns of  $\mathbf{A}$

1. they are independent if null space of  $\mathbf{A}$  is zero vector rank=n, no free variables
2. they are dependent if  $\mathbf{Ax} = 0$ , for some non-zero  $\mathbf{x}$ , rank < n, have free variables
3. vectors  $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$  span a space, means: the space consists of all combinations of those vectors.

Basis for a space is a sequence of vectors  $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_d$  with 2 properties.

1. they are independent
2. they span a space

**Giving a space, every basis for the space has the same number of vectors**, 就是不管你用什么基，只要构建的空间是同一个，则基的数量是一样的。我们把不变的数量的大小叫维度。由此，在解线性方程组时，矩阵  $\mathbf{A}$ , 列空间的维度等于矩阵主元列的个数 (秩 r)，零空间的维度等于自由列的个数  $(n - \text{rank}(\mathbf{A}))$ 。

## 10 The Four Fundamental Subspace

这 4 个基本子空间主要是矩阵  $\mathbf{A}$  的列空间  $C(\mathbf{A})$  和零空间  $N(\mathbf{A})$ ，以及其转置矩阵  $\mathbf{A}^T$  的  $C(\mathbf{A}^T)$  和零空间  $N(\mathbf{A}^T)$ ，假设矩阵  $\mathbf{A}$  is m by n

1. column space  $C(\mathbf{A})$  in  $\mathbf{R}^m$
2. null space  $N(\mathbf{A})$  in  $\mathbf{R}^n$
3. row space = all combinations of rows = all combinations of  $\mathbf{A}^T$  in  $\mathbf{R}^n$
4. null space of  $\mathbf{A}^T$ , we could call it as left null  $\mathbf{R}^m$

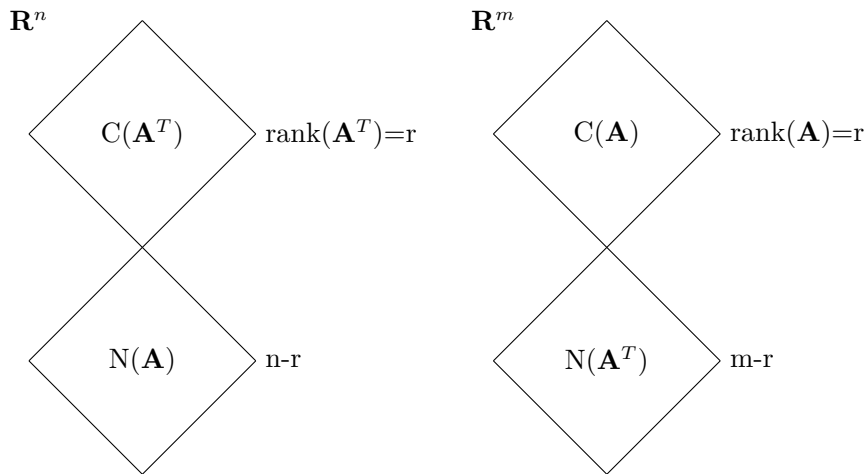


表 1: 4 个基本矩阵基和维度的确定

	$C(\mathbf{A})$	$N(\mathbf{A})$	$C(\mathbf{A}^T)$	$N(\mathbf{A}^T)$
basis	pivots columns of $\mathbf{A}$	free columns of $\mathbf{A}$	pivots columns of $\mathbf{A}^T$	free columns of $\mathbf{A}^T$
dim	r	n-r	r	m-r

## 11 Matrix spaces Rank 1-saml world Graphs

一个包含所有  $3 \times 3$  维的矩阵，共有 9 维，基可以表示为： $\begin{bmatrix} 1 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix}, \begin{bmatrix} 0 & 1 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix}, \begin{bmatrix} 0 & 0 & 1 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix}, \dots, \begin{bmatrix} 0 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 1 \end{bmatrix}$ 。

其子空间有

1. Symmetrix, 可以验证在  $3 \times 3$  空间里，维度为 6,  $\dim(\mathbf{S})=6$
2. Upper triangle, 可以验证在  $3 \times 3$  空间里，维度为 6,  $\dim(\mathbf{U})=6$

$$\begin{cases} \mathbf{S} \cap \mathbf{U} = \text{Symmetrix} \cap \text{Uppertriangle} = \text{Diagonal} 3 \times 3, \dim(\mathbf{S} \cap \mathbf{U}) = 3 \\ \mathbf{S} + \mathbf{U} = \text{anyelementof } \mathbf{S} \text{ anyelementof } \mathbf{U} = \text{allof } 3 \times 3, \dim(\mathbf{S} + \mathbf{U}) = 9 \end{cases}$$

可以得到维度计算公式： $\dim(\mathbf{S}) + \dim(\mathbf{U}) = \dim(\mathbf{S} \cap \mathbf{U}) + \dim(\mathbf{S} + \mathbf{U})$

结合微分方程

$$\frac{d^2 y}{dx^2} + y = 0$$

可以得到特解有  $\sin x, \cos x, e^{ix}$ ，但是由于是二阶微分方程，所以是有两个基，直接拿两个特解构建零空间就可以得到所有解了。所以完整解为：

$$y = c_1 \cos x + c_2 \sin x$$

下面讲一下秩为 1 的矩阵，可以表示为一列乘以一行，可以用秩为 1 的矩阵构造所有矩阵。


$$\mathbf{A} = \mathbf{U}\mathbf{V}^T$$

假设  $\mathbf{A} = \begin{bmatrix} 1 & 4 & 5 \\ 2 & 8 & 10 \end{bmatrix}$  则  $\mathbf{A}$  可以表示为  $\begin{bmatrix} 1 \\ 2 \end{bmatrix} \begin{bmatrix} 1 & 4 & 5 \end{bmatrix}$

世界好小：六人法则：只要通过 6 个人就可以连接到世界上任何一个人。

## 12 Graphs, Network, Incidence Matrices

世界万物可以看成是一个巨大的关系网 (突然想起了一句话, 世界万物是相互联系, 具有各种各样的关系), 网中存在节点, 在进行数学描述或建模研究时候可以得到关系图 (可能会更加复杂, 但是这个例子可以很好的启发, 甚至解释一切), 而矩阵可以描述图中的一些”关系”。假设有 4 个 nodes, 他们之间的联系有 5 条 edges, 则可以得到以下图形。



从实际问题中得到图, 让后得到关联矩阵  $\mathbf{A}$

表 2: incident matrix

Nodes				
1	2	3	4	edges
-1	1	0	0	edge1
0	-1	1	0	edge2
-1	0	1	0	edge3
-1	0	0	1	edge4
0	0	-1	1	edge5

表中-1 代表起点, 1 代表终点。则关系就可以用一张稀疏矩阵或者其他矩阵进行描述。可以发现 edge1, edge2, edge3 构成一个回路, 对应行向量相关, 从图中也可以明显的感觉到③=①+②, 在后面的叙述中可以验证这一结论。

接下来对零空间进行分析,  $\mathbf{A}x = 0$ :

$$\mathbf{A}x = \begin{bmatrix} x_2 - x_1 \\ x_3 - x_2 \\ x_3 - x_1 \\ x_4 - x_1 \\ x_4 - x_3 \end{bmatrix} = 0$$

由此可以计算边上上的差值, 若  $x_1, x_2, \dots, x_5$  代表电势, 则,  $\mathbf{A}x = 0$  可以分析电势差。很明显存在零解  $x = k \begin{bmatrix} 1 \\ 1 \\ 1 \\ 1 \\ 1 \end{bmatrix}$ ,

则  $\text{rank}(\mathbf{A}) = n - \dim(N(\mathbf{A})) = 3$ 。

对左零空间进行分析, 即  $\mathbf{A}^T y = 0$ , 可计算出维度  $N(\mathbf{A}^T) = 5 - 3$


$$\mathbf{A}y = \begin{bmatrix} -1 & 0 & -1 & -1 & 0 \\ 1 & -1 & 0 & 0 & 0 \\ 0 & 1 & 1 & 0 & -1 \\ 0 & 0 & 0 & 1 & 1 \end{bmatrix} \begin{bmatrix} y_1 \\ y_2 \\ y_3 \\ y_4 \\ y_5 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \\ 0 \\ 0 \end{bmatrix}$$

可以得到

$$\begin{cases} -y_1 - y_3 - y_4 = 0 \\ y_1 - y_2 = 0 \\ y_2 + y_3 - y_5 = 0 \\ y_4 + y_5 = 0 \end{cases}$$

(7)

再看图



很明显上式可以表示出图中的关系，已知  $N(\mathbf{A}^T) = 2$ ，则选择两个基就行了。解得

$$y = k_1 \begin{bmatrix} 1 \\ 1 \\ -1 \\ 0 \\ 0 \end{bmatrix} + k_2 \begin{bmatrix} 0 \\ 0 \\ 1 \\ -1 \\ 1 \end{bmatrix}$$

可以得到一个结论，欧拉公式：  $\# \text{ loops} = \# \text{ edges} - (\# \text{ nodes} - 1)$

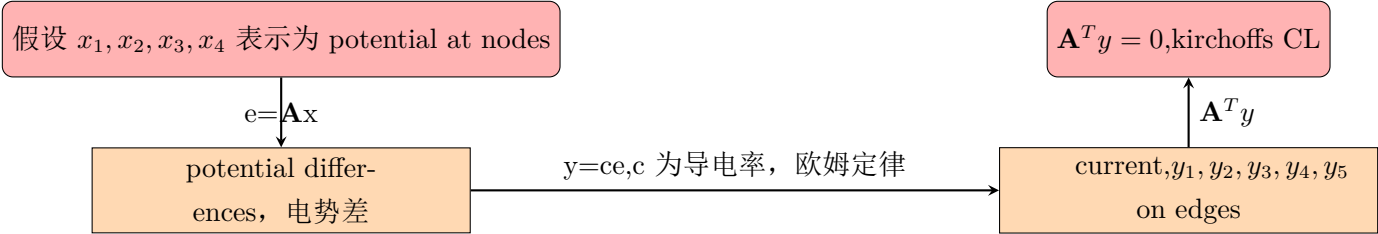


图 3: 电势建模分析流程

通过图3可以得到公式  $\mathbf{A}^T \mathbf{C} \mathbf{A} \mathbf{x} = 0$

13 Quiz review

$N(\mathbf{C}\mathbf{D})=N(\mathbf{D})$ ,if C is invertible

14 Orthogonal Vectors and subspaces


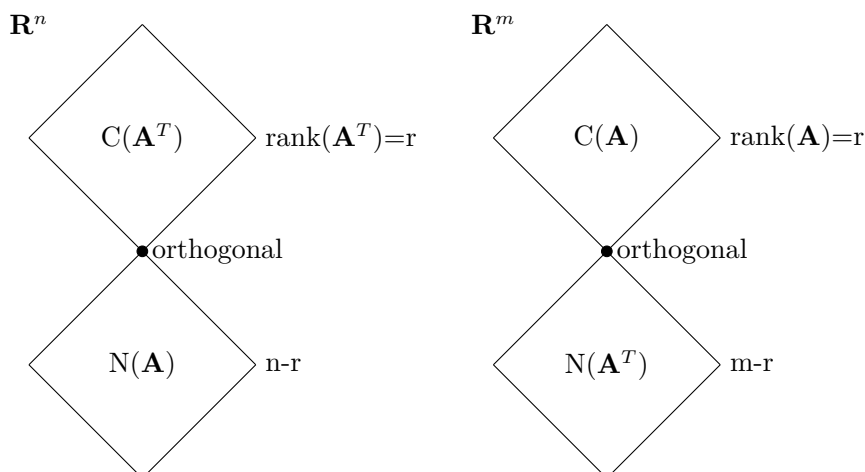


图 4: 正交向量

由勾股定理可得:  $\|x\|^2 + \|y\|^2 = \|x + y\|^2 \Rightarrow x^T y = 0$ 。两个空间正交是指任何空间 S 中的向量正交于任何空间 T 中的向量, **Subsapce S is orthogonal to subspace T means: every vector in S is orthogonal to every vector in T**, 对于四个基本空间, 可得到:



Row space is orthogonal to null space, 通过  $Ax = 0$  就可清除看到, 行空间正交于零空间, 下进行证明: 可以看到所有行垂直于 x

$$\begin{bmatrix} \text{row}_1 & \text{of} & \mathbf{A} \\ \text{row}_2 & \text{of} & \mathbf{A} \\ \dots & & \\ \text{row}_m & \text{of} & \mathbf{A} \end{bmatrix} x = \begin{bmatrix} 0 \\ 0 \\ \dots \\ 0 \end{bmatrix}$$

下面证明列空间垂直 x, 行空间就是主元行的线性组合, 因此就是证明主元行的线性组合垂直于 x

$$\left. \begin{array}{l} c_1(\text{row}_1 \text{ of } A)^T x = 0 \\ c_2(\text{row}_2 \text{ of } A)^T x = 0 \end{array} \right\} \Rightarrow \underbrace{(c_1(\text{row}_1 \text{ of } A)^T + c_2(\text{row}_2 \text{ of } A)^T)}_{\text{row sapce}} x = 0$$

coming:  $Ax = b$  when there is no solution  $m > n$ , How to solve 将在下一节进行详细讲解, 这里先提一下, 在两边同乘矩阵  $A^T$ :

$$A^T A \hat{x} = A^T b$$

这里用到了最小二乘法的原理, 原方程组在列空间中找不到向量 b, 只能找一个和 b 相似的向量, 而两点之间, 直线最短, 所以将向量 b 沿着列空间平面的法线方向投影到列空间平面, 夹角越小则误差越小。

## 15 Projections onto subspace

这一节用到了投影定理和最小二乘法原理, 下图为二维空间下的一个投影示意图:




图 5: 投影示意图

根据向量空间中两条垂直的向量的内积为零，可以得到

$$\begin{aligned}\mathbf{a}^T(\mathbf{b} - x\mathbf{a}) &= 0 \\ \mathbf{a}^T\mathbf{b} &= x\mathbf{a}^T\mathbf{a} \\ x &= \frac{\mathbf{a}^T\mathbf{b}}{\mathbf{a}^T\mathbf{a}}\end{aligned}$$

假设投影矩阵为


$$\text{project} = \mathbf{P} \text{matrix} \times \text{vector}$$

$$p = \mathbf{P}b, p = \frac{\mathbf{a}\mathbf{a}^T}{\mathbf{a}^T\mathbf{a}}b$$

则投影矩阵  $\mathbf{P}$  为

$$P = \frac{\mathbf{a}\mathbf{a}^T}{\mathbf{a}^T\mathbf{a}}$$


投影矩阵有啥用？可以 solve  $Ax=b$ , when equations has no solution, 因为在  $C(\mathbf{A})$  空间中找不到  $b$ , 所以只能在  $C(\mathbf{A})$  中找到一个与  $b$  最相近的解 (猜测：估计是两点之间直线最短，然后沿着  $C(\mathbf{A})$  的法线方向做投影，这样保证  $\hat{b}, b$  夹角最小，从而最相似)，也就是  $b$  在  $C(\mathbf{A})$  中的投影。



由于  $\hat{p}$  在列空间内所以  $p = x_1 a_1 + x_2 a_2 = A\hat{x}$ , 因为  $e \perp$  the column space of  $A$ , 可以得到下面公式:

$$\left\{ \begin{array}{l} \left[ \begin{array}{c} \mathbf{a}_1^T \\ \mathbf{a}_2^T \end{array} \right] (b - A\hat{x}) = \left[ \begin{array}{c} 0 \\ 0 \end{array} \right] \\ \mathbf{A}^T (b - A\hat{x}) = 0 \end{array} \right\} \Rightarrow \mathbf{A}^T \mathbf{A} \hat{x} = \mathbf{A}^T b$$

这个公式  $\mathbf{A}^T \mathbf{A} \hat{x} = \mathbf{A}^T b$  很重要, 可以解决方程组无解是的问题。下面举一个列子。



很明显  $m > n$ , 两个未知数, 三个方程, 在列空间中找不到  $b$ , 所以只能在列空间找一个相似的  $\hat{b}$

$$\left\{ \begin{array}{l} C + D = 1 \\ C + 2D = 2 \\ C + 3D = 2 \end{array} \right\} \Rightarrow \begin{bmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \end{bmatrix} \begin{bmatrix} C \\ D \end{bmatrix} = \begin{bmatrix} 1 \\ 2 \\ 2 \end{bmatrix}$$

## 16 Projection Matrix and Least Squares

下图解释了如何将无解方程组  $Ax = b$  中的  $b$  投影到列空间, 然后得出最优解, 但使用数据过程中要避免数据污染 (数据中存在较高或较低的数值)。





图 6: 投影示意图 (图中  $b$  是垂直分解)

投影矩阵  $\mathbf{P} = \mathbf{A}(\mathbf{A}^T \mathbf{A})^{-1} \mathbf{A}^T$ , 可以验证:

*if  $b$  in column space,  $\mathbf{P}b = b$*

*if  $b \perp$  column space,  $\mathbf{P}b = 0$*



已知点 (1,1), (2,2), (3,2), 求其回归方程, 假设为线性方程, 则建设直线表达式为  $y = \hat{C} + \hat{D}x$ , 其实就是将这些点代入假设的线性模型, 求模型参数  $\hat{x} = \begin{bmatrix} \hat{C} \\ \hat{D} \end{bmatrix}$ , 注意这里的模型参数也是使用变量  $x$ 。

根据  $\mathbf{A}^T \mathbf{A}x = \mathbf{A}^T b$  得到:

$$\left. \begin{array}{l} C + D = 1 \\ C + 2D = 2 \\ C + 3D = 2 \end{array} \right\} \Rightarrow \begin{bmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \end{bmatrix} \begin{bmatrix} C \\ D \end{bmatrix} = \begin{bmatrix} 1 \\ 2 \\ 2 \end{bmatrix}$$

$$\mathbf{A}^T \mathbf{A} = \begin{bmatrix} 1 & 1 & 1 \\ 1 & 2 & 3 \end{bmatrix} \begin{bmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \end{bmatrix} = \begin{bmatrix} 3 & 6 \\ 6 & 14 \end{bmatrix} \Rightarrow \begin{cases} 3C + 6D = 5 \\ 6C + 14D = 11 \end{cases}, \begin{cases} C = \hat{C} = 2/3 \\ D = \hat{D} = 1/2 \end{cases}$$

这里得到模型参数  $\hat{x} = \begin{bmatrix} \hat{C} \\ \hat{D} \end{bmatrix}$  后, 就得到  $\hat{b}$  了, 这里的  $\hat{b}$  位于列空间内, 图中以画出  $\hat{C} + \hat{D}x = \hat{b}$  直线了, 虽然得到的

数值  $\hat{b} = \begin{bmatrix} 7/6 \\ 5/3 \\ 13/6 \end{bmatrix}$  与准确值  $b = \begin{bmatrix} 1 \\ 2 \\ 2 \end{bmatrix}$  有一定的误差, 当但是这误差从全局考虑是最小的。  $e = \begin{bmatrix} e_1 \\ e_2 \\ e_3 \end{bmatrix} = \begin{bmatrix} -1/6 \\ 1/3 \\ -1/6 \end{bmatrix}$ , 满足

$\mathbf{b} = \mathbf{p} + \mathbf{e}$ , 这里  $p = \mathbf{A}\hat{x} = \hat{b}$ ,  $b = \hat{b} + e$ 。


证明, if  $\mathbf{A}$  has independent columns, the  $\mathbf{A}^T \mathbf{A}$  is invertible, 也就是证明  $\mathbf{A}^T \mathbf{A}x = 0$  只有零解。

suppose  $\mathbf{A}^T \mathbf{A}x = 0$


IDEA  $\mathbf{x}^T \mathbf{A}^T \mathbf{A}x = 0 \Rightarrow (\mathbf{A}x)^T \mathbf{A}x = 0$ , 显然两个数的平方要为零, 则两个都为零  $\mathbf{A}x = 0$ , 有且只有零解  $\Rightarrow \mathbf{A}^T \mathbf{A}x = 0$  只有零解。

columns definitely independent if they are prep unit vectors, 下图为常见的一个三维标准正交基:  
orthonormal vector





下面为三角函数基



## 17 Orthogonal Matrices and Gram-Schmidt

首先讲一下正交标准向量，满足：


$$q_i^T q_j = \begin{cases} 0, & \text{if } i \neq j \\ 1, & \text{if } i = j \end{cases}$$

则：

$$\mathbf{Q}^T \mathbf{Q} = \begin{bmatrix} q_1^T \\ q_2^T \\ \vdots \\ q_n^T \end{bmatrix} \begin{bmatrix} q_1 & q_2 & \cdots & q_n \end{bmatrix} = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & 1 \end{bmatrix} = \mathbf{I}$$

$\mathbf{Q}^T \mathbf{Q} = \mathbf{I}$  (if  $\mathbf{Q}$  is square then  $\mathbf{Q}^T \mathbf{Q} = \mathbf{I}$ , tells us  $\mathbf{Q}^T = \mathbf{Q}^{-1}$ ),  $\mathbf{Q}$  has orthonormal columns project onto its column space,  $\mathbf{P} = \mathbf{Q}(\mathbf{Q}^T \mathbf{Q})^{-1} \mathbf{Q}^T = \mathbf{Q} \mathbf{Q}^T (= \mathbf{I}, \text{if } \mathbf{Q} \text{ is square})$

下面说一说 **Gram-Schmidt**，也就是**格拉姆-施密特正交化**，它可以将不互相正交的向量转变为互相正交，而转变后的列空间没有发生变化，还是和原来一样。利用投影知识



现有  $\mathbf{a}$  和  $\mathbf{b}$  两个向量，两者不正交，利用投影定理，先固定其中一个向量  $\mathbf{a}$ ，作为第一个正交向量，然后  $\mathbf{b}$  减去  $\mathbf{b}$  在  $\mathbf{a}$  中的投影，就可以得到垂直于  $\mathbf{A}$  的向量了，因为此时已经不包含  $\mathbf{a}$  分量了，所以得到向量一定与  $\mathbf{a}$  正交。下图解释了施密特正交化的过程




图 7: 施密特标准正交化流程解析

下面举一个例子，向量  $\vec{a} = \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}$  和向量  $\vec{b} = \begin{bmatrix} 1 \\ 0 \\ 2 \end{bmatrix}$  的正交化过程如下：

$$\mathbf{A} = a = \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}$$

$$\mathbf{B} = b - \mathbf{P}_{b \rightarrow a} = \begin{bmatrix} 1 \\ 0 \\ 2 \end{bmatrix} - \frac{\begin{bmatrix} 1 & 1 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ 0 \\ 2 \end{bmatrix}}{\begin{bmatrix} 1 & 1 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}} \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix} = \begin{bmatrix} 1 \\ 0 \\ 2 \end{bmatrix} - \frac{3}{3} \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix} = \begin{bmatrix} 0 \\ -1 \\ 1 \end{bmatrix}$$

$$q_1 = \frac{\mathbf{A}}{\|\mathbf{A}\|} = \frac{1}{\sqrt{3}} \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}, q_2 = \frac{\mathbf{B}}{\|\mathbf{B}\|} = \frac{1}{\sqrt{2}} \begin{bmatrix} 0 \\ -1 \\ 1 \end{bmatrix}, \mathbf{Q} = [q_1 \ q_2] = \begin{bmatrix} \frac{1}{\sqrt{3}} & 0 \\ \frac{1}{\sqrt{3}} & -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{3}} & \frac{1}{\sqrt{2}} \end{bmatrix}$$

与  $\mathbf{A} = \mathbf{LU}$  分解一样，矩阵正交分解也可以表示为  $\mathbf{A} = \mathbf{QR}$ ，已知  $\mathbf{A} = \begin{bmatrix} 1 & 1 \\ 1 & 0 \\ 1 & 2 \end{bmatrix}$  求出  $\mathbf{R} = \mathbf{Q}^T \mathbf{A}$

$$\mathbf{R} = \mathbf{Q}^T \mathbf{A} = \begin{bmatrix} q_1^T \\ q_2^T \end{bmatrix} \begin{bmatrix} a_1 & a_2 \end{bmatrix} = \begin{bmatrix} \sqrt{3} & \sqrt{3} \\ 0 & \sqrt{2} \end{bmatrix}$$

所以矩阵  $\mathbf{A} = \mathbf{QR}$  表示为：

$$\begin{bmatrix} \frac{1}{\sqrt{3}} & 0 \\ \frac{1}{\sqrt{3}} & -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{3}} & \frac{1}{\sqrt{2}} \end{bmatrix} \begin{bmatrix} \sqrt{3} & \sqrt{3} \\ 0 & \sqrt{2} \end{bmatrix}$$

## 18 Properties of Determinants

行列式具有许多重要的性质，在这一节将进行一个中介，首先主要考虑方正的行列式形式。

$$1. \det \mathbf{A} = 1, \begin{vmatrix} 1 & 0 \\ 0 & 1 \end{vmatrix} = 1$$

$$2. \text{exchange rows: reverse sign of } \det \begin{vmatrix} 0 & 1 \\ 1 & 0 \end{vmatrix} = -1 \text{ 置换矩阵 } \mathbf{P} \text{ 的行列式为: } \det \mathbf{P} = \begin{cases} 1, \text{even} \\ -1, \text{odd} \end{cases}.$$

$$3. \left. \begin{array}{l} (a) \text{ multiply by number, } \begin{vmatrix} ta & tb \\ c & d \end{vmatrix} = t \begin{vmatrix} a & b \\ c & d \end{vmatrix} \\ (b) \text{ add, } \begin{vmatrix} a+a' & b+b' \\ c & d \end{vmatrix} = \begin{vmatrix} a & b \\ c & d \end{vmatrix} + \begin{vmatrix} a' & b' \\ c & d \end{vmatrix} \end{array} \right\} \text{说明行列式对每行具有线性关系 (数乘 + 加法), 及 linear for each row}$$

4. 2 equal rows  $\rightarrow \det \mathbf{A}=0$ 。通过前面的公式可以验证，交换两行之后矩阵仍然一样，他们的行列也一样，由于进行行互换，变为原矩阵行列式的负值，要使结果仍然相等，则矩阵的行列式应该为零。

$$5. \text{ subtract } l \times \text{row from row } k, \det \text{ doesn't change. } \begin{vmatrix} a & b \\ c & d \end{vmatrix} = \begin{vmatrix} a & b \\ c-al & d-lb \end{vmatrix} = \begin{vmatrix} a & b \\ c & d \end{vmatrix} + \underbrace{\begin{vmatrix} a & b \\ -la & -ld \end{vmatrix}}_{\text{according to 4 property, we know this is 0}}$$

6. row of zeros  $\rightarrow \det \mathbf{A}=0$

7.

$$\det \mathbf{U} = \begin{vmatrix} d_1 & * & * \\ 0 & d_2 & * \\ \dots & \dots & \dots \\ * & * & d_n \end{vmatrix} = d_1 d_2 \cdots d_n$$

证明

$$\det \mathbf{U} = \begin{vmatrix} d_1 & * & * \\ 0 & d_2 & * \\ \dots & \dots & \dots \\ * & * & d_n \end{vmatrix} = d_1 d_2 \cdots d_n \begin{vmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ \dots & \dots & \dots \\ 0 & 0 & 1 \end{vmatrix}$$

8.  $\det \mathbf{A}=0$  when  $\mathbf{A}$  is singular (row of zeros)

$\det \mathbf{A} \neq 0$ , when  $\mathbf{A}$  is invertible ( $\mathbf{U} \rightarrow \mathbf{D} \rightarrow d_1 d_2 \cdots d_n$ )

9.  $\det \mathbf{AB} = \det \mathbf{A} \det \mathbf{B}$ ,

当  $\mathbf{B} = \mathbf{A}^{-1}$  时

$$\det \mathbf{A}^{-1} = \frac{1}{\det \mathbf{A}}$$

可以看到，当  $\det \mathbf{A}=0$  时，无意义，不可逆。 $\det \mathbf{A} \neq 0$  时，有意义，矩阵  $\mathbf{A}$  可逆。

于是我们可以达到其他公式

$$\begin{aligned} \det \mathbf{A}^2 &= (\det \mathbf{A})^2 \\ \det(2\mathbf{A}^2) &= 2^n \det \mathbf{A} \end{aligned}$$

10.  $\det \mathbf{A}^T = \det \mathbf{A}$

$$\begin{vmatrix} a & b \\ c & d \end{vmatrix} = \begin{vmatrix} a & c \\ b & d \end{vmatrix} = ad - cb$$

该性质说明所有行的性质也同样适用于列，比如行线性变换。

证明：

$$\begin{aligned} |\mathbf{A}^T| &= |\mathbf{A}| \\ |\mathbf{U}^T \mathbf{L}^T| &= |\mathbf{L} \mathbf{U}| \\ |\mathbf{U}^T| |\mathbf{L}^T| &= |\mathbf{L}| |\mathbf{U}| \end{aligned}$$

可以看到，这里两边均为三角形分解，行列式得值为对角线相乘，而  $\mathbf{L} \mathbf{U}$  都相等，所以两边都相等。

## 19 Determinant Formular and cofactor

利用上一节的行列式性质 1,2,3, 可以得到行列式的计算公式。

$$1 \det \mathbf{A} = 1, \begin{vmatrix} 1 & 0 \\ 0 & 1 \end{vmatrix} = 1$$

$$2 \text{ exchange rows: reverse sign of } \det \begin{vmatrix} 0 & 1 \\ 1 & 0 \end{vmatrix} = -1 \text{ 置换矩阵 P 的行列式为: } \det \mathbf{P} = \begin{cases} 1, \text{even} \\ -1, \text{odd} \end{cases}$$

$$3 \left. \begin{array}{l} (a) \text{ multiply by number, } \begin{vmatrix} ta & tb \\ c & d \end{vmatrix} = t \begin{vmatrix} a & b \\ c & d \end{vmatrix} \\ (b) \text{ add, } \begin{vmatrix} a+a' & b+b' \\ c & d \end{vmatrix} = \begin{vmatrix} a & b \\ c & d \end{vmatrix} + \begin{vmatrix} a' & b' \\ c & d \end{vmatrix} \end{array} \right\} \text{说明行列式对每行具有线性关系 (数乘 + 加法), 及 linear for each row}$$

推理过程如下: ,

首先在 2 by 2 的矩阵中

$$\begin{vmatrix} a & b \\ c & d \end{vmatrix} = \underbrace{\begin{vmatrix} a & 0 \\ c & d \end{vmatrix}} + \underbrace{\begin{vmatrix} 0 & b \\ c & d \end{vmatrix}} = \begin{vmatrix} a & 0 \\ 0 & d \end{vmatrix} + \begin{vmatrix} 0 & b \\ c & 0 \end{vmatrix} = ad - bc$$

$$\begin{vmatrix} a & 0 \\ c & 0 \end{vmatrix} + \begin{vmatrix} a & 0 \\ 0 & d \end{vmatrix} \quad \begin{vmatrix} 0 & b \\ c & 0 \end{vmatrix} + \begin{vmatrix} 0 & b \\ 0 & d \end{vmatrix}$$

在 2 by 2 矩阵中, 按照行线性性质 (加法), 首先可以逐个取第一行的元素构造矩阵, 构造的矩阵符合加法原则, 然后在构造的矩阵中逐个取第二行元素再次构造矩阵。共有  $2 \times 2 = 4$  个矩阵。

myheiti 在三维矩阵中

$$\begin{vmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{vmatrix} = \underbrace{\begin{vmatrix} a_{11} & 0 & 0 \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{vmatrix}} + \begin{vmatrix} 0 & a_{12} & 0 \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{vmatrix} + \begin{vmatrix} 0 & 0 & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{vmatrix}$$

$$\underbrace{\begin{vmatrix} a_{11} & 0 & 0 \\ a_{21} & 0 & 0 \\ a_{31} & a_{32} & a_{33} \end{vmatrix}} + \begin{vmatrix} a_{11} & 0 & 0 \\ 0 & a_{22} & 0 \\ a_{31} & a_{32} & a_{33} \end{vmatrix} + \begin{vmatrix} a_{11} & 0 & 0 \\ 0 & 0 & a_{23} \\ a_{31} & a_{32} & a_{33} \end{vmatrix}$$

$$\begin{vmatrix} a_{11} & 0 & 0 \\ a_{21} & 0 & 0 \\ a_{31} & 0 & 0 \end{vmatrix} + \begin{vmatrix} a_{11} & 0 & 0 \\ a_{21} & 0 & 0 \\ 0 & a_{32} & 0 \end{vmatrix} + \begin{vmatrix} a_{11} & 0 & 0 \\ a_{21} & 0 & 0 \\ 0 & 0 & a_{33} \end{vmatrix}$$

可以发现在三维矩阵中, 每一行分解个数是 3, 所以总共有  $3 \times 3 \times 3 = 27$  个矩阵, 可以发现大多矩阵, 在最后都为零, 得到矩阵最后的结果为:

$$\begin{vmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{vmatrix} = \begin{vmatrix} a_{11} & 0 & 0 \\ 0 & a_{22} & 0 \\ 0 & 0 & a_{33} \end{vmatrix} + \begin{vmatrix} a_{11} & 0 & 0 \\ 0 & 0 & a_{23} \\ 0 & a_{32} & 0 \end{vmatrix} + \begin{vmatrix} a_{11} & 0 & 0 \\ 0 & 0 & a_{23} \\ 0 & 0 & a_{33} \end{vmatrix} + \begin{vmatrix} 0 & a_{12} & 0 \\ a_{21} & 0 & 0 \\ 0 & 0 & a_{33} \end{vmatrix} + \begin{vmatrix} 0 & a_{12} & 0 \\ 0 & 0 & a_{23} \\ 0 & a_{32} & 0 \end{vmatrix} + \begin{vmatrix} 0 & 0 & a_{13} \\ a_{21} & 0 & 0 \\ 0 & a_{32} & 0 \end{vmatrix} + \begin{vmatrix} 0 & 0 & a_{13} \\ 0 & a_{22} & 0 \\ a_{31} & 0 & 0 \end{vmatrix}$$

$$\det \mathbf{A} = a_{11}a_{22}a_{33} - a_{11}a_{23}a_{32} - a_{12}a_{21}a_{33} + a_{12}a_{23}a_{31} + a_{13}a_{21}a_{32} - a_{13}a_{22}a_{31}$$

由此可以得到行列式的公式, **Big Formular**

$$\det \mathbf{A} = \sum_{n! \text{ terms}} (sign) a_{1\alpha} a_{2\beta} a_{3\gamma} \cdots a_{n\omega}$$

其中  $(\alpha, \beta, \gamma, \dots, \omega) = \text{permutation of } (1, 2, 3, \dots, n)$ , 这里是对所有列进行组合的意思, 共有  $C_n^1 = n!$  种。下面看一下利用 Big Formula 的列子。

$$\begin{vmatrix} 0 & 0 & \underline{1} & \underline{1} \\ 0 & 1 & \underline{1} & 0 \\ 1 & \underline{1} & 0 & 0 \\ \underline{1} & 0 & 0 & 1 \end{vmatrix}$$

可以看到这里有两个列组合, 下划线一类  $(4, 3, 2, 1) +$ , 然后是没有下划线的  $(3, 2, 1, 4) -$ 。下面讲一下 cofactors, 及代数余子式, 首先看一下  $3 \times 3$  的矩阵的代数余子式是啥:

$$\begin{aligned} & a_{11}(a_{22}a_{33} - a_{23}a_{32}) + \\ \det \mathbf{A} &= a_{12}(\dots) + \\ & a_{13}(\dots) \end{aligned}$$

这里的 co meaning going with  $a_{ij}$ , 在括号里面的部分就是代数余子式。由此, 可以通过代数余子式可以得到另一个非常重要的计算行列式的公式:

$$\begin{aligned} \det \mathbf{A} &= a_{11}\mathbf{C}_{11} + a_{12}\mathbf{C}_{12} + \dots + a_{1n}\mathbf{C}_{1n} \\ \mathbf{C}_{ij} &= \text{cofactor of } a_{ij} = \pm \det(n-1 \text{ matrix with row}_i \text{ and col}_j \text{ erased}) \end{aligned}$$

其中  $\pm$  的选取原则是当  $i+j$  为偶数时为正, 奇数是为负。

下面讲一下三对角线矩阵, 及他的性质, 以后可能会遇到, 这里先保存下来。

$$\begin{vmatrix} 1 & 1 & 0 & 0 \\ 1 & 1 & 1 & 0 \\ 0 & 1 & 1 & 1 \\ 0 & 0 & 1 & 1 \end{vmatrix}$$

$$|\mathbf{A}_1| = 1, |\mathbf{A}_2| = 0, |\mathbf{A}_3| = -1, |\mathbf{A}_4| = |\mathbf{A}_3| - |\mathbf{A}_2| \Rightarrow |\mathbf{A}_n| = |\mathbf{A}_{n-1}| - |\mathbf{A}_{n-2}|$$

这里记  $D_n = \det \mathbf{A}_n$ , 所以可得到一个二阶差分方程  $D_n = D_{n-1} - D_{n-2}$  当需要求  $D_{100}$  时的行列式, 怎么求?, 进行线性转换 (将二阶差分方程  $\rightarrow$  一阶向量方程)。

$$\begin{bmatrix} D_n \\ D_{n-1} \end{bmatrix} = \begin{bmatrix} 1 & -1 \\ 1 & 0 \end{bmatrix} \begin{bmatrix} D_{n-1} \\ D_{n-2} \end{bmatrix}$$

然后结合初始值  $D_1 = 1, D_2 = 0$  则可以计算出  $D_{100}$  的值, 可以参考后面 21 章节 Diagonalization and Powers of A

## 20 Gramer's Rule, inverse Matrix and Volumn

### 20.1 Inverse

首先来一个 2 by 2 的矩阵看一下怎么算矩阵的逆矩阵:

$$\begin{bmatrix} a & b \\ c & d \end{bmatrix}^{-1} = \frac{1}{ad-bc} \underbrace{\begin{bmatrix} d & -b \\ -ca & a \end{bmatrix}}_{\text{adjoint matrix}}$$

可以看到求矩阵的逆, 需要知道矩阵的行列式, 以及代数余子式, 也就是  $\mathbf{A}^{-1} = \frac{1}{\det \mathbf{A}} \mathbf{C}^T$ , 我们可以验证一下,  $\mathbf{A}^{-1} = \frac{1}{\det \mathbf{A}} \mathbf{C}^T \Leftrightarrow \mathbf{A} \mathbf{C}^T = (\det \mathbf{A}) \mathbf{A}$  于是可得:

$$\begin{bmatrix} a_{11} & a_{12} & \dots & a_{1n} \\ a_{21} & a_{22} & \dots & a_{2n} \\ \dots & \dots & \ddots & \vdots \\ a_{n1} & a_{n2} & \dots & a_{nn} \end{bmatrix} \begin{bmatrix} c_{11} & c_{21} & \dots & c_{n1} \\ c_{12} & c_{22} & \dots & c_{n2} \\ \dots & \dots & \ddots & \vdots \\ c_{1n} & c_{2n} & \dots & c_{nn} \end{bmatrix} = \begin{bmatrix} \det \mathbf{A} & 0 & 0 & 0 \\ 0 & \det \mathbf{A} & 0 & 0 \\ \dots & \dots & \ddots & \vdots \\ 0 & 0 & 0 & \det \mathbf{A} \end{bmatrix} = (\det \mathbf{A}) \mathbf{I}$$

由于

某一行  $\times$  对应的代数余子式  $= \det \mathbf{A}$

某一行  $\times$  其他行对应的代数余子式  $= 0$ 。

所以可以得到验证。

## 20.2 Grammer's Rule


其实这个法则在上线性代数的时候就已经讲过了，这里在说一下，主要是用于求解  $\mathbf{A}x = b, x = \mathbf{A}^{-1}b = \frac{1}{\det \mathbf{A}} \mathbf{C}^T b$ 。

$$\begin{aligned} x &= \frac{1}{\det \mathbf{A}} \mathbf{C}^T b \\ x_1 &= \frac{\det \mathbf{B}_1}{\det \mathbf{A}} \\ x_2 &= \frac{\det \mathbf{B}_2}{\det \mathbf{A}} \\ &\dots \\ x_j &= \frac{\det \mathbf{B}_j}{\det \mathbf{A}} \end{aligned}$$

这里的  $\mathbf{B}_j = \mathbf{A}$  with column  $j$  replaced by  $b$ , 就用  $b$  替换掉矩阵  $\mathbf{A}$  中的  $j$  列后，得到的矩阵就为  $\mathbf{B}_j$  然后计算行列式相除就可以的结果。

## 20.3 Volumn


$|\det \mathbf{A}| = \text{volumn of box}$




可以看到，当行列式为：

$$\det \mathbf{A} = \begin{vmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{vmatrix}, \text{ if } \mathbf{A} = \mathbf{I}, \det \mathbf{A} = \begin{vmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{vmatrix} = 1$$

若变扩大两倍，根据行线性相乘原理，边扩大两倍，体积也扩大两倍。然而，在二维时，行列式表示的是面积，如下图所示：



可以看到二维行列式  $\begin{vmatrix} a & b \\ c & d \end{vmatrix} = ad - bc$  为平行四边形的面积, 若求三角形面积  $\triangle OAB$  的面积, 则为  $\frac{1}{2}(ad - bc)$ 。但是如果图形不在原点怎么办, 下面进行一个简单的操作, 原理上是线段的中点坐标减去起点坐标, 这样就可以转变为起点为零的向量了。



得到矩阵

$$\begin{vmatrix} x_1 & y_1 & 1 \\ x_2 & y_2 & 1 \\ x_3 & y_3 & 1 \end{vmatrix} \Rightarrow \begin{vmatrix} x_1 & y_1 & 1 \\ x_2 - x_1 & y_2 - y_1 & 1 \\ x_3 - x_1 & y_3 - y_1 & 1 \end{vmatrix}$$

## 21 Eigenvalue and Eigenvectors

特征值和特征向量, 特向向量的定义:

矩阵乘以一个向量, 后仍和原来的向量平行, 那个这个向量就叫做特征向量


$$\mathbf{A}x = \lambda x \quad (8)$$

从投影矩阵的角度看一下这个问题: 假设这个向量在列空间内, 那么这个向量在列空间里面, 在列空间里面投影后仍然不变, 若这个向量垂直于列空间, 则投影后的为零。

1. any  $x$  in  $\text{plan } \mathbf{A}x = \lambda x, \lambda = 1$
2. any  $x \perp \text{plan } \mathbf{A}x = 0$

那怎么求一个矩阵的特征值和特征向量呢?, 看一下两个重要的公式。

1.  $\lambda_1 + \lambda_2 + \cdots + \lambda_n = a_{11} + a_{22} + \cdots + a_{nn}$
2.  $\det \mathbf{A} = \lambda_1 \lambda_2 \cdots \lambda_n$



可以相看一下  $\mathbf{A}x = \lambda x$ , 有两个未知数  $\lambda, x$  不好求, 移一下项得:

$$(\mathbf{A} - \lambda \mathbf{I})x = 0$$

要使上面这个等式成立, 则  $(\mathbf{A} - \lambda \mathbf{I})$  应该为奇异矩阵, 然后得出他的行列式  $\det(\mathbf{A} - \lambda \mathbf{I}) = 0$ , 就可以先计算出  $\lambda$  啦, 然后再求  $x$ 。下面看一下 2 by 2 的矩阵怎么求特征值与特征向量的:

$$\mathbf{A} = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}, \det(\mathbf{A} - \lambda \mathbf{I}) = \begin{vmatrix} -\lambda & 1 \\ 1 & -\lambda \end{vmatrix} = \lambda^2 - 1 = 0 \Rightarrow \lambda_1 = 1, \lambda_2 = -1$$

下面分别求  $\lambda_1 = 1, \lambda_2 = -1$  对应的特征向量。

$$\lambda_1 = 1, (\mathbf{A} - \lambda \mathbf{I})x = \begin{bmatrix} -1 & 1 \\ 1 & -1 \end{bmatrix} x = 0, x_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

$$\lambda_1 = -1, (\mathbf{A} - \lambda \mathbf{I})x = \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix} x = 0, x_2 = \begin{bmatrix} -1 \\ 1 \end{bmatrix}$$

为进行对比分析, 求另一个矩阵的特征值和特征向量:

$$\mathbf{A} = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}, \det(\mathbf{A} - \lambda \mathbf{I}) = \begin{vmatrix} 3-\lambda & 1 \\ 1 & 3-\lambda \end{vmatrix} = (3-\lambda)^2 - 1 = 0 \Rightarrow \lambda_1 = 4, \lambda_2 = 2$$

$$\lambda_1 = 4, (\mathbf{A} - \lambda \mathbf{I})x = \begin{bmatrix} -1 & 1 \\ 1 & -1 \end{bmatrix} x = 0, x_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

$$\lambda_1 = 2, (\mathbf{A} - \lambda \mathbf{I})x = \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix} x = 0, x_2 = \begin{bmatrix} -1 \\ 1 \end{bmatrix}$$

我们可以惊讶的发现, 这两个矩阵的特征向量一样, 而特征值是在前一个矩阵上分别加三。

至此, 我们可以得到公式 if  $\mathbf{A}x = \lambda x \Rightarrow (\mathbf{A} + 3\mathbf{I})x = \mathbf{A}x + 3x = (\lambda + 3)x$

注意这里可以进行相加是因为两个矩阵的特征向量一样, 有时候会不一样, 则不能相加。如

$$\text{if } \mathbf{A}x = \lambda x, \mathbf{B}x = \alpha x, (\mathbf{A} + \mathbf{B})x \neq (\lambda + \alpha)x$$

因为这个时候矩阵  $\mathbf{A}, \mathbf{B}$  对应的特征向量不应定相等。



## 22 Diagonalization and Powers of A

由于矩阵在未对角化之前，如果计算矩阵的幂，将会非常困难。比如求  $\mathbf{A}^{100}$  是多少？我们可以先将矩阵对角化，然后在计算  $\mathbf{A}^{100}$  就比较方便了，下面看看矩阵对角化是啥😄，如下所示

$$\mathbf{S}^{-1}\mathbf{A}\mathbf{S} = \Lambda$$

可以看到如果矩阵可以对角化，则必须存在  $\mathbf{S}$  可逆。透露一下，这里的  $\mathbf{S}$  其实就是矩阵  $\mathbf{A}$  的特征向量。

suppose n independent eigenvector of  $\mathbf{A}$ , put them in columns of  $\mathbf{S}$ , and then

$$\mathbf{A}\mathbf{S} = \mathbf{A} \begin{bmatrix} x_1 & x_2 & \cdots & x_n \end{bmatrix} = \begin{bmatrix} \lambda_1 x_1 & \lambda_2 x_2 & \cdots & \lambda_n x_n \end{bmatrix} = \begin{bmatrix} x_1 & x_2 & \cdots & x_n \end{bmatrix} \begin{bmatrix} \lambda_1 & 0 & 0 & 0 \\ 0 & \lambda_2 & 0 & 0 \\ \cdots & \cdots & \ddots & \vdots \\ 0 & 0 & 0 & \lambda_n \end{bmatrix} = \mathbf{S}\Lambda$$

那么关键问题来了，怎么保证  $\mathbf{S}$  可逆，也就是 **eigenvectors are independent**，如果矩阵  $\mathbf{A}$  有 n 个不同的特征值，矩阵  $\mathbf{A}$  就有 n 个不同的特征向量。则矩阵  $\mathbf{A}$  的对角化表示为  $\mathbf{A} = \mathbf{S}\mathbf{A}\mathbf{S}^{-1}$ ，则可以求得  $\mathbf{A}^k$ ：

$$\mathbf{A}^2 = \mathbf{S}\mathbf{A}\mathbf{S}^{-1}\mathbf{S}\mathbf{A}\mathbf{S}^{-1} = \mathbf{S}\mathbf{A}^2\mathbf{S}^{-1}$$

$$\mathbf{A}^3 = \mathbf{S}\mathbf{A}\mathbf{S}^{-1}\mathbf{S}\mathbf{A}\mathbf{S}^{-1}\mathbf{S}\mathbf{A}\mathbf{S}^{-1} = \mathbf{S}\mathbf{A}^3\mathbf{S}^{-1}$$

...

$$\mathbf{A}^n = \mathbf{S}\mathbf{A}^n\mathbf{S}^{-1}$$

通过矩阵对角化，我们可以很快的求出  $\mathbf{A}^k$  的值，如果通过  $\mathbf{A} = \mathbf{L}\mathbf{U}$  分解求解  $\mathbf{A}^k = (\mathbf{L}\mathbf{U})^k$ ，则计算过程很复杂。通过矩阵对角化方法，只要求出特征值和特征向量就行了。

$$if \mathbf{A}x = \lambda x$$

$$\mathbf{A}^2x = \lambda\mathbf{A}x = \lambda^2x$$

$$\mathbf{A}^3x = \lambda\mathbf{A}^2x = \lambda^3x$$

...

$$\mathbf{A}^nx = \lambda^nx$$

**theorem**，什么时候  $\mathbf{A}^k$  趋近于 0。

if all  $|\lambda| < 1$ , 则 as  $k \rightarrow \infty$

$$\mathbf{A}^k \rightarrow 0$$

### 22.1 the application of $\mathbf{A}^k$

equation  $u_{k+1} = \mathbf{A}u_k$ , start with given vector  $u_0$

$$u_1 = \mathbf{A}u_0, u_2 = \mathbf{A}u_1 = \mathbf{A}^2u_0, \cdots, u_k = \mathbf{A}^ku_0,$$

to really solve

$$\vec{u}_0 = c_1\vec{x}_1 + c_2\vec{x}_2 + \cdots + c_n\vec{x}_n$$

$$\mathbf{A}\vec{u}_0 = c_1\mathbf{A}\vec{x}_1 + c_2\mathbf{A}\vec{x}_2 + \cdots + c_n\mathbf{A}\vec{x}_n = c_1\lambda_1\vec{x}_1 + c_2\lambda_2\vec{x}_2 + \cdots + c_n\lambda_n\vec{x}_n$$

$$\mathbf{A}^{100}\vec{u}_0 = c_1\lambda_1^{100}\vec{x}_1 + c_2\lambda_2^{100}\vec{x}_2 + \cdots + c_n\lambda_n^{100}\vec{x}_n$$

$$if \vec{u}_0 = \mathbf{S}c, \mathbf{A}^{100}\vec{u}_0 = \mathbf{S}\Lambda^{100}\mathbf{S}^{-1}\vec{u}_0 = \mathbf{S}\Lambda^{100}\mathbf{S}^{-1}\mathbf{S}c = \mathbf{S}\Lambda^{100}c$$

下面通过计算 Fibnacc，将上面这些等式加以运用，所谓斐波那契数是指这样的一个序列，后一个数是前两个数的和，如 0,1,1,2,3,5,8,13,21,...，问  $F_{100}$  为多少？

构造一个线性方程组 (把二阶标量方程转化为了一阶向量方程组)

$$\begin{cases} F_{k+2} = F_{k+1} + F_k \\ F_{k+1} = F_k \end{cases}, u_k = \begin{bmatrix} F_{k+1} \\ F_k \end{bmatrix}, \mathbf{A} = \begin{bmatrix} 1 & 1 \\ 1 & 0 \end{bmatrix}, u_0 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$$

于是我们可以以矩阵  $\times$  向量的形式表示这个线性方程组。

$$u_{k+1} = \mathbf{A}u_k = \begin{bmatrix} 1 & 1 \\ 1 & 0 \end{bmatrix} u_k$$

求得矩阵  $\mathbf{A}$  的特征值  $\lambda_1 = \frac{1+\sqrt{5}}{2} \approx 1.618, \lambda_2 = \frac{1-\sqrt{5}}{2} \approx -0.618$ , 可以看两个特征值不相同可以对角化。对应的特征向量为:

$$x_1 = \begin{bmatrix} \lambda_1 \\ 1 \end{bmatrix} = \begin{bmatrix} 1.618 \\ 1 \end{bmatrix}, x_2 = \begin{bmatrix} \lambda_2 \\ 1 \end{bmatrix} = \begin{bmatrix} -0.618 \\ 1 \end{bmatrix}$$

然后利用  $u_0 = c_1x_1 + c_2x_2$ , 即可求得  $c_1, c_2$

$$\begin{aligned} u_{100} &= \mathbf{A}^{100}u_0 = c_1\lambda_1^{100}x_1 + c_2\lambda_2^{100}x_2 \\ \begin{bmatrix} F_{101} \\ F_{100} \end{bmatrix} &= c_1\lambda_1^{100} \begin{bmatrix} \lambda_1 \\ 1 \end{bmatrix} + c_2\lambda_2^{100} \begin{bmatrix} \lambda_2 \\ 1 \end{bmatrix} \\ F_{100} &= c_1\lambda_1^{100} + c_2\lambda_2^{100} = c_1(1.618)^{100} + \underbrace{c_2(-0.618)^{100}}_{\text{very small}} \end{aligned}$$

通过上述方法可以很好的求解出斐波那契数

## 23 Differential equations and $\exp(\mathbf{A}t)$

### 23.1 解一阶常系数线性微分方程组

首先讲一下怎么解一阶常系数线性微分方程组, 然后可以扩展到 2 阶, 3 阶, ..., n 阶。解一阶常系数线性微分方程组, 就是将其转化为线性代数, 然后求解。(first derivative, constant coefficient linear equations turns to linear algebra)

两个一阶常系数线性微分方程组如下,  $u_1 = u_1(t), u_2 = u_2(t)$

$$\begin{cases} \frac{du_1}{dt} = -u_1 + 2u_2 \\ \frac{du_2}{dt} = u_1 - 2u_2 \end{cases}$$

可以看到  $u_1(t), u_2(t)$  两个函数相互影响, 也就是耦合。那怎么解耦呢? (通过对角化, 及求特征值和特征向量) 转化为线性代数的知识如下:

$$\frac{du}{dt} = \mathbf{A}u, \mathbf{A} = \begin{bmatrix} -1 & 2 \\ 1 & -2 \end{bmatrix}, u = \begin{bmatrix} u_1 \\ u_2 \end{bmatrix} \text{ known } U(0) = \begin{bmatrix} u_1(0) \\ u_2(0) \end{bmatrix} = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$$

观察初始值  $U(0) = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$  和线性方程组, 可看到随时间  $\frac{du_2}{dt} > 0, u_1$  为正, 所以  $u_1$  流向  $u_2$ , 然后从  $u_1$  流出来, so

we'll just follow that movement as times goes farword.

求解  $\lambda_1, \lambda_2$  的值。

$$\det(\mathbf{A} - \lambda\mathbf{I}) = \begin{vmatrix} -1-\lambda & 2 \\ 1 & -2-\lambda \end{vmatrix} = \lambda^2 + 3\lambda = 0, \lambda_1 = 0, \lambda_2 = -3$$

求解  $x_1, x_2$  的值。

$$\text{put } \lambda_1 \text{ into } (\mathbf{A} - \lambda \mathbf{I})x_1 = 0$$

$$\begin{bmatrix} -1 & 2 \\ 1 & -2 \end{bmatrix} \begin{bmatrix} 2 \\ 1 \end{bmatrix} = 0, x_1 = \begin{bmatrix} 2 \\ 1 \end{bmatrix}$$

$$\text{put } \lambda_1 \text{ into } (\mathbf{A} - \lambda \mathbf{I})x_1 = 0$$

$$\begin{bmatrix} 2 & 2 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} -1 \\ 1 \end{bmatrix} = 0, x_2 = \begin{bmatrix} -1 \\ 1 \end{bmatrix}$$

微分方程组  $\frac{du}{dt} = \mathbf{A}u$  解的形式为  $U(t) = c_1 e^{\lambda_1 t} x_1 + c_2 e^{\lambda_2 t} x_2, \text{ maybe } + \dots$  可以将解  $u_1 = e^{\lambda_1 t} x_1$  代入微分方程组中:

$$\lambda_1 e^{\lambda_1 t} x_1 = \mathbf{A} e^{\lambda_1 t} x_1, \lambda_2 e^{\lambda_2 t} x_2 = \mathbf{A} e^{\lambda_2 t} x_2$$

由此, 我们可以得到求解微分方程组的解, 主要是求矩阵特征值, 所以可以得到结果:

$$U(t) = c_1 1 \begin{bmatrix} 2 \\ 1 \end{bmatrix} + c_2 e^{-3t} \begin{bmatrix} -1 \\ 1 \end{bmatrix}$$

已知

$$U(0) = \begin{bmatrix} 1 \\ 0 \end{bmatrix}, c_1 \begin{bmatrix} 2 \\ 1 \end{bmatrix} + c_2 \begin{bmatrix} 1 \\ -1 \end{bmatrix} = \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \Rightarrow \begin{bmatrix} 2 & 1 \\ 1 & -1 \end{bmatrix} \begin{bmatrix} c_1 \\ c_2 \end{bmatrix} = \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \Rightarrow Sc = u(0), c_1 = 1/3, c_2 = 1/3$$

得到  $c_1, c_2$  后, 得出解为:

$$U(\infty) = 1/3 \begin{bmatrix} 2 \\ 1 \end{bmatrix}$$

从上面的例题中可以发现, 方程组具有稳定解非常重要。

1. stability.  $u(t) \rightarrow 0$ , need  $\text{Re } \lambda_i < 0$
2. steady state.  $\lambda_1 = 0$ , and other  $\text{Re } \lambda < 0$
3. Blow up. if any  $\text{Re } \lambda > 0$

下面看一下只需要实部小于零就可以得到稳态解, 假设  $\lambda = -3 + 6i$

$$|e^{(-3+6i)t}| = |e^{-3t}| |e^{6it}|, |e^{6it}| = |\cos(6t) + i\sin(6t)| = 1$$

**A couples  $u_1, u_2$ , the whole point of eigenvectors is to uncouple,** 下面讲解一下实现过程:

$$\frac{du}{dt} = \mathbf{A}u, \text{ set } u = \mathbf{S}v, \mathbf{S} \text{ are eigenvectors}$$

可以得到:

$$\mathbf{S} \frac{dv}{dt} = \mathbf{A} \mathbf{S} v, \frac{dv}{dt} = \mathbf{S}^{-1} \mathbf{A} \mathbf{S} v = \Lambda v$$

$$\frac{dv_1}{dt} = \lambda_1 v_1$$

$$\frac{dv_2}{dt} = \lambda_2 v_2$$

...

$$\frac{dv_n}{dt} = \lambda_n v_n$$

联系上一章二阶标量方程的解, 然后对比:

$$U_{k+1} = \mathbf{A} U_k$$

$$U_k \approx c_1 \lambda_1^k x_1 + c_2 \lambda_2^k x_2 + \dots$$

$$U(t) = c_1 e^{\lambda_1 t} x_1 + c_2 e^{\lambda_2 t} x_2 + \dots$$

可以看到二阶标量的解和线性微分方程的解有一定的相似，这样便于记忆。继续分析：

$$v(t) = e^{\Lambda t} v(0)$$

$$u(t) = \mathbf{S} e^{\Lambda t} \mathbf{S}^{-1} u(0) = e^{\mathbf{A} t} u(0)$$

下面验证一下  $e^{\mathbf{A} t} = \mathbf{S} e^{\Lambda t} \mathbf{S}^{-1}$ ，有之前学过的级数，我们可知：

$$e^x = \sum_0^{\infty} \frac{x^n}{n!}$$

$$\frac{1}{1-x} = \sum_0^{\infty} x^n$$

于是

$$e^{\mathbf{A} t} = \mathbf{I} + \mathbf{A} t + \frac{(\mathbf{A} t)^2}{2} + \frac{(\mathbf{A} t)^3}{6} + \dots + \frac{(\mathbf{A} t)^n}{n!}$$

$$= \mathbf{S} \mathbf{S}^{-1} + \mathbf{S} \Lambda \mathbf{S}^{-1} t + \frac{\mathbf{S} \Lambda^2 \mathbf{S}^{-1} t^2}{2} + \frac{\mathbf{S} \Lambda^3 \mathbf{S}^{-1} t^3}{6} + \dots + \frac{\mathbf{S} \Lambda^n \mathbf{S}^{-1} t^n}{n!}$$

$$= \mathbf{S} e^{\Lambda t} \mathbf{S}^{-1}$$

$$(\mathbf{I} - \mathbf{A} t)^{-1} = \mathbf{I} + \mathbf{A} t + (\mathbf{A} t)^2 + (\mathbf{A} t)^3 + \dots + (\mathbf{A} t)^n, |\lambda(\mathbf{A} x)| < 1$$

注意：级数都要考虑收敛半径

## 23.2 解二阶或 n 阶常系数线性微分方程组

考虑二阶常系数线性微分方程组  $y'' + by' + ky = 0$

$$\text{set } u = \begin{bmatrix} y' \\ y \end{bmatrix}, u' = \begin{bmatrix} y'' \\ y' \end{bmatrix}$$

$$\Rightarrow u' = \begin{bmatrix} y'' \\ y' \end{bmatrix} = \begin{bmatrix} -b & -k \\ 1 & 0 \end{bmatrix} \begin{bmatrix} y' \\ y \end{bmatrix}$$

假设有 5 阶，则得到矩阵  $\mathbf{A}$  为：

$$\begin{bmatrix} - & - & - & - & - \\ 1 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 \end{bmatrix}$$

## 24 Markov Matrices, Fourier Series

先记一个单词😊：perpendicular，垂直的。

### 24.1 Markov Matrices

首先看一个马尔科夫矩阵：

$$\mathbf{A} = \begin{bmatrix} 0.1 & 0.01 & 0.3 \\ 0.2 & 0.99 & 0.3 \\ 0.7 & 0 & 0.4 \end{bmatrix}$$

马尔科夫矩阵具有的特点：

1. all entries  $\geq 0$
2. all columns add to 1

我们可以得到马尔科夫矩阵的特征值具有的特点：

1.  $\lambda = 1$  是矩阵  $\mathbf{A}$  的一个特征值。
2. all other  $|\lambda_i| < 1$

为啥马尔科夫矩阵的特征值里面一定有一个为 1，下面给出这证明，将  $\lambda = 1$  代入  $\mathbf{A} - \lambda \mathbf{I} = 0$  中，如果结果成立，这说明  $\lambda = 1$  为矩阵  $\mathbf{A}$  的一个特征值。

$$\mathbf{A} - \lambda \mathbf{I} = \begin{bmatrix} 0.1 & 0.01 & 0.3 \\ 0.2 & 0.99 & 0.3 \\ 0.7 & 0 & 0.4 \end{bmatrix} - \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} = \begin{bmatrix} -0.9 & 0.01 & 0.3 \\ 0.2 & -0.01 & 0.3 \\ 0.7 & 0 & -0.6 \end{bmatrix}$$

可以很明显的发现，上面这个矩阵是一个奇异矩阵，因为矩阵的行是相关的， $(1,1,1)$  is in  $n(\mathbf{A}^T)$ ，在行空间中包含一个非零解。因为矩阵的特征值，与矩阵转置后的特征值，两者是一样的。我们可以验证：

$$\left. \begin{array}{l} \det(\mathbf{A} - \lambda \mathbf{I}) = 0 \\ \text{transpose both side :} \\ \det(\mathbf{A}^T - \lambda \mathbf{I}) = 0 \end{array} \right\} \Rightarrow \det(\mathbf{A} - \lambda \mathbf{I}) = \det(\mathbf{A}^T - \lambda \mathbf{I})$$

下面举一个有关马尔科夫矩阵应用的例子，假设加州 (California) 原有人口 0 人，麻省 (Massachusetts) 原有人口 1000 人。每一年，加州有 0.9 的人选择留在加州，0.1 的选择去麻省；麻省有 0.2 的人选择去加州，0.8 选择留在麻省。问 100 年后的人口变化。

可建立如下线性方程组解决：

$$\begin{bmatrix} u_{cal} \\ u_{mass} \end{bmatrix}_{t=k+1} = \begin{bmatrix} 0.9 & 0.2 \\ 0.1 & 0.8 \end{bmatrix} \begin{bmatrix} u_{cal} \\ u_{mass} \end{bmatrix}_{t=k}, \quad \begin{bmatrix} u_{cal} \\ u_{mass} \end{bmatrix}_{t=0} = \begin{bmatrix} 0 \\ 1000 \end{bmatrix}$$

根据前面的知识，可以得到该方程的解为： $u_k = \mathbf{A}^k u_0 = c_1 \lambda_1^k x_1 + c_2 \lambda_2^k x_2$ ，下面求解矩阵的特征值和特征向量：

$$\lambda_1 = 1, \lambda_2 = 0.7$$

$$\begin{bmatrix} -0.1 & 0.2 \\ 0.1 & -0.2 \end{bmatrix} x_1 = 0, x_1 = \begin{bmatrix} 2 \\ 1 \end{bmatrix}$$

$$\begin{bmatrix} 0.2 & 0.2 \\ 0.1 & 0.1 \end{bmatrix} x_2 = 0, x_2 = \begin{bmatrix} -1 \\ 1 \end{bmatrix}$$

所以

$$u_k = c_1 1^k \begin{bmatrix} 2 \\ 1 \end{bmatrix} + c_2 0.7^k \begin{bmatrix} -1 \\ 1 \end{bmatrix}$$

$c_1, c_2$  可根据  $t=k=0$  的初始条件求出

$$c_1 \begin{bmatrix} 2 \\ 1 \end{bmatrix} + c_2 \begin{bmatrix} -1 \\ 1 \end{bmatrix} = \begin{bmatrix} 0 \\ 1000 \end{bmatrix}$$

## 24.2 Fourier Series

有关正交基的一个应用：傅里叶级数。

*projection with orthonormal basis :  $q_1, q_2, \dots, q_n$*

*any  $v$  :*

*$v = x_1 q_1 + x_2 q_2 + \dots + x_n q_n$ , how to get the  $x_i$*

*because them are orthonormal basis, so*

$$q_1^T v = x_1 q_1^T q_1 + \underbrace{x_2 q_1^T q_2 + \dots + x_n q_1^T q_n}_{=0}$$

$$x_1 = \frac{q_1^T v}{q_1^T q_1}, \text{ and then } x_2 = \frac{q_2^T v}{q_2^T q_2}, \dots, x_n = \frac{q_n^T v}{q_n^T q_n}$$

从上面可以看出，在正交标准基所构建的空间中，得到的  $v$ ，分别对各基向量构成的空间中做投影，即可得到  $x_i$ ，而傅里叶级数可以将  $v$  表示为：

$$f(x) = \underbrace{a_0 + a_1 \cos x + b_1 \sin x + a_2 \cos 2x + b_2 \sin 2x + \dots + a_n \cos nx + b_n \sin(nx)}_{\text{the number of dimension maybe no limit}}. \quad (9)$$

可以看到这里使用了正交三角函数代替了正交向量 (这里也好理解，函数只不过将取值范围扩大了点，向量是由固定的点组成的，而函数向量是由无穷的点构成的)。传统的向量内积定义：

$$\mathbf{v}^T \mathbf{w} = v_1^T w_1 + v_2^T w_2 + \dots + v_n^T w_n$$

函数向量内积定义：

$$f^T g = \int f(x)g(x)dx$$

这里三角基函数的周期为  $2\pi$ ，其内积为

$$f^T g = \int_0^{2\pi} f(x)g(x)dx = 0$$

其中  $f(x), g(x)$  为三角基函数中的任一个 (不相等)，比如：

$$f^T g = \int_0^{2\pi} \sin x \cos x dx = 0$$

前面正交基的性质，我们可以求出傅里叶级数的系数  $a_0, b_0, \dots, a_n, b_n$

$$f(x) = a_0 + a_1 \cos x + b_1 \sin x + a_2 \cos 2x + b_2 \sin 2x + \dots + a_n \cos nx + b_n \sin(nx)$$

integrate both side :

$$\begin{aligned} \int_0^{2\pi} f(x) \cos x dx &= \int_0^{2\pi} (a_0 + a_1 \cos x + b_1 \sin x + a_2 \cos 2x + b_2 \sin 2x + \dots + a_n \cos nx + b_n \sin(nx)) dx \\ &= \underbrace{a_0 \int_0^{2\pi} \cos x dx}_{=0} + \\ &\quad \underbrace{a_1 \int_0^{2\pi} \cos x \cos x dx}_{=\pi} + \underbrace{b_1 \int_0^{2\pi} \sin x \cos x dx + \dots + a_n \int_0^{2\pi} \cos nx \cos x dx + b_n \int_0^{2\pi} \sin nx \cos x dx}_{=0} \\ &\Rightarrow a_1 = \frac{1}{\pi} \int_0^{2\pi} f(x) \cos x dx \end{aligned}$$

根据正交基的正交关系，我们可以求出其他的系数，amazing 😊

## 25 Quiz 2 review

先记一个单词 😊 : tedious /'ti:diəs/ 冗长的。We had to listen to the tedious details of his operation  
这场是对前面的一些回顾，看看前面的知识，所以没啥笔记。

## 26 Symmetrix Matrices and Positive Definiteness

本章主要讲的实数范围内的对称矩阵，还不涉及复数！，后面将会涉及到实数范围内的对称矩阵。  
实对称矩阵具有的性质：

1. the eigenvalues are real
2. the eigenvectors are perpendicular(expect the repeated eigenvectors)

实对称矩阵对角化与一般矩阵对角化区别：实对称矩阵一定存在  $n$  个相互正交的特征向量，也就是说对相同的  $k$  重特征根，也具有  $k$  个不相关正交的特征向量 (通过正交化)。

$$usual\ case : \mathbf{A} = \mathbf{S}\mathbf{\Lambda}\mathbf{S}^{-1}$$

$$symmetric\ case : \mathbf{A} = \mathbf{Q}\mathbf{\Lambda}\mathbf{Q}^{-1} = \mathbf{Q}\mathbf{\Lambda}\mathbf{Q}^T$$

为啥实对称矩阵的特征值一定为实数，下面做出证明：

$$\begin{aligned} \mathbf{A}x = \lambda x &\stackrel{conjugate}{\Rightarrow} \mathbf{A}\bar{x} = \bar{\lambda}\bar{x} \stackrel{transpose}{\Rightarrow} \bar{x}^T \mathbf{A}^T = \bar{x}^T \bar{\lambda} \\ \left. \begin{aligned} \mathbf{A}x = \lambda x &\Rightarrow \bar{x}^T \mathbf{A}x = \bar{x}^T \lambda x \\ \bar{x}^T \mathbf{A}^T = \bar{x}^T \bar{\lambda} &\Rightarrow \bar{x}^T \mathbf{A}^T x = \bar{x}^T \bar{\lambda} x \end{aligned} \right\} \mathbf{A} = \mathbf{A}^T \Rightarrow \bar{x}^T \lambda x = \bar{x}^T \bar{\lambda} x \Rightarrow \lambda = \bar{\lambda} \Rightarrow \lambda \text{ is real.} \end{aligned}$$

将实对称矩阵进行分解可得到：

$$\mathbf{A} = \mathbf{Q}\mathbf{\Lambda}\mathbf{Q} = \begin{bmatrix} q_1 & q_2 & \cdots & q_n \end{bmatrix} \begin{bmatrix} \lambda_1 & 0 & 0 & 0 \\ 0 & \lambda_2 & 0 & 0 \\ \cdots & \cdots & \ddots & \vdots \\ 0 & 0 & 0 & \lambda_n \end{bmatrix} \begin{bmatrix} q_1^T \\ q_2^T \\ \cdots \\ q_n^T \end{bmatrix} = \lambda_1 q_1 q_1^T + \lambda_2 q_2 q_2^T + \cdots + \lambda_n q_n q_n^T.$$

其中  $q_1 q_1^T, q_2 q_2^T, \dots, q_n q_n^T$  是投影矩阵，所以可以得到这样的结论，每一个对称矩阵是由正交投影矩阵进行组合得到的。

对于实对称矩阵而言：

1. signs of pivots as same as signs of  $\lambda$ 's.
2.  $\#$  positive pivots =  $\#$  positive  $\lambda$ 's. 知道特征值的符号，我们可以判断矩阵是否稳态。

下面讲一下 positive matrix(正定矩阵) 满足一下条件：

1. all eigenvalues are positive
2. all pivots are e definite symmetric
3. all sub determinants are positive

## 27 Complex matrices, Fast Fourier Transform

### 27.1 Complex matrices

先记一个单词😊：unitary /'ju:nəteri/ 统一的。It would be important to do this in a way that maintained the unitary nature of the board, but that could surely be managed.

先看一看在复数域下求向量的模：

$$\mathbf{Z} = \begin{bmatrix} z_1 \\ z_2 \\ \cdots \\ z_n \end{bmatrix}, z_i \text{ in } \mathbb{C}^n$$

如果像以前一样使用内积， $z_1 = 3+5i, z_1 z_1 = (3+5i)(3+5i) = -16+30i$ , and then  $z_1 z_1 + z_2 z_2 + \dots + z_n z_n = a+bi$ , 这样得到得数就包含虚数  $i$ ，在求模  $|z^T z|$  时显然不合适。所以，先求共轭  $\bar{z}$ ，在求内积求模  $\bar{z}^T z$  比较合适。

先看一看在复数域下两个向量的内积：

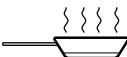
$$\bar{z}^T z = z^H z, H \text{ means the name of Hermite.}$$

同理对称矩阵复数域标记变为  $\bar{\mathbf{A}}^T = \mathbf{A} \rightarrow \mathbf{A}^H = \mathbf{A}$

if

$$\mathbf{Q} = \begin{bmatrix} q_1 & q_2 & \cdots & q_n \end{bmatrix}$$

$$q_i^H q_i = \begin{cases} 0, i \neq j \\ 1, i = j \end{cases}$$


则  $\mathbf{Q}^H \mathbf{Q} = \mathbf{I}$ ,  $\mathbf{Q}$  is unitary matrix(酉矩阵), 在实数域则称为正交矩阵。对比记忆 .

## 27.2 Fast Fourier Transform

傅里叶矩阵:

$$\mathbf{F}_n = \begin{bmatrix} 1 & 1 & 1 & \cdots & 1 \\ 1 & w & w^2 & \cdots & w^{n-1} \\ 1 & w^2 & w^4 & \cdots & w^{2(n-1)} \\ \cdots & \cdots & \cdots & \ddots & \cdots \\ 1 & w^{n-1} & w^{2(n-1)} & \cdots & w^{(n-1)(n-1)} \end{bmatrix}, (\mathbf{F}_n)_{ij} = w^{ij}, i, j = 0, 1, \dots, n-1. w^n = 1, w = e^{i2\pi/n} = \cos \frac{2\pi}{n} + i \sin \frac{2\pi}{n}$$

现在假设  $n=6$ , 则  $w$  可以表示如下:



同理  $n=4$  时:  $w = i2\pi/4 = \cos(\pi/2) + i\sin(\pi/2) = i, i^2 = -1, i^3 = -i, i^4 = 1$ . 可得

$$\mathbf{F}_4 = \begin{bmatrix} 1 & 1 & 1 & 1 \\ 1 & i & i^2 & i^3 \\ 1 & i^2 & i^4 & i^6 \\ 1 & i^3 & i^6 & i^9 \end{bmatrix} = \begin{bmatrix} 1 & 1 & 1 & 1 \\ 1 & i & -1 & -i \\ 1 & -1 & 1 & -1 \\ 1 & -i & -1 & i \end{bmatrix}$$

现在求  $\mathbf{F}_{64}$ , 满足下面关系:

$$\mathbf{F}_{64} = \begin{bmatrix} \mathbf{I} & \mathbf{D} \\ \mathbf{I} & -\mathbf{D} \end{bmatrix} \begin{bmatrix} \mathbf{F}_{32} & 0 \\ 0 & \mathbf{F}_{32} \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 & 0 & 0 & 0 & \cdots & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 & 0 & \cdots & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 & 0 & \cdots & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & \cdots & 1 & 0 \\ \hline 0 & 1 & 0 & 0 & 0 & 0 & \cdots & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 & 0 & \cdots & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 & \cdots & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & \cdots & 0 & 1 \end{bmatrix}$$

注意: the even column of last matrix is 1 above the dotted line, the odd column of last matrix is 1 under the line of dashed.



## 28 Positive definite and Matrices Minima

以 2 by 2 矩阵为例，讲解一下如何判定正定矩阵。

$$\begin{bmatrix} a & b \\ b & c \end{bmatrix}$$

1. 特征值,  $\lambda_1 > 0, \lambda_2 > 0$
2. 顺序主子式为零,  $a > 0, ac - b^2 > 0$
3. pivots,  $a > 0, \frac{ac - b^2}{a} > 0$
4.  $x^T \mathbf{A} x > 0$ , 化成 quadratic form(二次型) 判断最值。

举一个例子，矩阵：

$$\mathbf{A} = \begin{bmatrix} 2 & 6 \\ 6 & 18 \end{bmatrix}$$

则其二次型为：

$$x^T \mathbf{A} x = \begin{bmatrix} x_1 & x_2 \end{bmatrix} \begin{bmatrix} 2 & 6 \\ 6 & 18 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \underbrace{2x_1^2 + 12x_1x_2 + 18x_2^2}_{ax^2 + 2bxy + cy^2} = 2(x_1 + 3x_2)^2 \geq 0$$

很明显，这时矩阵的特征值存在 0，我们称为 positive semi-definite matrix(半正定矩阵)。

当矩阵  $\mathbf{A}$  为

$$\begin{bmatrix} 2 & 6 \\ 6 & 7 \end{bmatrix}$$

很明显最小值为负，不是正定矩阵。

当矩阵  $\mathbf{A}$  为


$$\begin{bmatrix} 2 & 6 \\ 6 & 20 \end{bmatrix}$$

很明显  $x^T \mathbf{A} x > 0$ ，一定是正定矩阵。

回顾计算微积分时，求最小值过程：MIN 存在的话，在定义域内存在某点一阶导数  $f'(x_0) = 0$ ，二阶导数  $f''(x_0) > 0$ ，这里引用过来的话就是：二阶导数  $f''(x_0) > 0 \Rightarrow$  Matrix of 2nd Derivative is positive definite, 即  $f''(x^T \mathbf{A} x) > 0$ 。假设二次型为：

$$x^T \mathbf{A} x = \begin{bmatrix} x_1 & x_2 \end{bmatrix} \begin{bmatrix} 2 & 6 \\ 6 & 18 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = 2x_1^2 + 12x_1x_2 + 18x_2^2 = 2(x_1 + 3x_2)^2, \text{ use } x, y \text{ to express : } 2(x + 3y)^2$$

假设取  $x^T \mathbf{A} x = 2(x + 3y)^2 = 2$ ，则其截面为一个椭圆。(图示可能有误，只可意会，不可言传)




可以看到用  $z=2$  的平面截到的图形为一个椭圆，此时最小值为 0，可以确定这是一个半正定矩阵。当矩阵为一个 3 by 3 则其截到的东西为一个椭圆体。假设矩阵：

$$\begin{bmatrix} 2 & -1 & 0 \\ -1 & 2 & -1 \\ 0 & -1 & 2 \end{bmatrix}$$

对应的二次型为：  $f(x) = 2x_1^2 + 2x_2^2 + 2x_3^2 - 2x_1x_2 - 2x_2x_3 > 0$ ，由

$$\mathbf{A} = \mathbf{Q}\mathbf{\Lambda}\mathbf{Q}^T$$

根据主轴定理，特征向量对应轴向，特征值对应长度



## 29 similar matrices and Jordan Form

if  $\mathbf{A}, \mathbf{B}$  are positive definites,  $\mathbf{A} + \mathbf{B}$  also is positive definites. 可以证明：

$$\left. \begin{array}{l} \mathbf{x}^T \mathbf{A} \mathbf{x} > 0 \\ \mathbf{x}^T \mathbf{B} \mathbf{x} > 0 \end{array} \right\} \mathbf{x}^T \mathbf{A} + \mathbf{B} \mathbf{x} > 0, \text{ so } \mathbf{A} + \mathbf{B} \text{ is positive definites matrix}$$

我很容易知道  $\mathbf{A}^T \mathbf{A}$  一定是方阵和对称矩阵，但是不是正定矩阵呢？答案是的，下面进行一个简单的验证：

$$\mathbf{x}^T \mathbf{A}^T \mathbf{A} \mathbf{x} = (\mathbf{A} \mathbf{x})^T \mathbf{A} \mathbf{x} = \|\mathbf{A} \mathbf{x}\|^2 > 0$$

$\mathbf{A}^T \mathbf{A}$  是一个方正，具有对称，正定的特点，在奇异值分解过程中就可以看其应用。

### 29.1 similar Matrix

$\mathbf{A}, \mathbf{B}$  相似，则：存在一些矩阵  $\mathbf{M}$

$$\mathbf{B} = \mathbf{M}^{-1} \mathbf{A} \mathbf{M}$$

由定义可知，矩阵对角化得到的对角矩阵，与原矩阵相似。  $\mathbf{S}^{-1} \mathbf{A} \mathbf{S} = \mathbf{\Lambda}$

$$\mathbf{A} = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}, \mathbf{\Lambda} = \begin{bmatrix} 3 & 0 \\ 0 & 1 \end{bmatrix}$$

由于  $\mathbf{M}$  是任意产生的，可逆都行，所以相似矩阵具有很多。

$$\underbrace{\begin{bmatrix} 1 & -4 \\ 0 & 1 \end{bmatrix}}_{\mathbf{M}^{-1}} \underbrace{\begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}}_{\mathbf{A}} \underbrace{\begin{bmatrix} 1 & 4 \\ 0 & 1 \end{bmatrix}}_{\mathbf{M}} = \begin{bmatrix} -2 & -15 \\ 0 & 6 \end{bmatrix}, \text{ so } \mathbf{A} = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix} \text{ is similar to } \begin{bmatrix} -2 & -15 \\ 0 & 6 \end{bmatrix}$$

由于  $\mathbf{M}$  可以取不同的值，所以具有对应不同的相似矩阵，所有的相似矩阵具有一个共同的特点，对角线之和相等，即特征值之和相等。如

$$\begin{bmatrix} 3 & 7 \\ 0 & 1 \end{bmatrix}, \begin{bmatrix} 1 & 7 \\ 0 & 3 \end{bmatrix} \text{ all are similar to } \mathbf{A} = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}$$

所有的相似矩阵具有相同的特征值，验证如下：

$$\begin{aligned} \mathbf{A}\mathbf{x} &= \lambda x \\ \mathbf{A} \underbrace{\mathbf{M}\mathbf{M}^{-1}}_{\mathbf{I}} x &= \lambda x \\ \mathbf{M}^{-1}\mathbf{A}\mathbf{M}\mathbf{M}^{-1}x &= \mathbf{M}^{-1}\lambda x \\ \text{if } \mathbf{B} &= \mathbf{M}^{-1}\mathbf{A}\mathbf{M} \\ \mathbf{B}\mathbf{M}^{-1}x &= \lambda \mathbf{M}^{-1}x \end{aligned}$$

可以看到相似矩阵  $\mathbf{B}$  的特征向量  $=\mathbf{M}^{-1}$  乘以矩阵  $\mathbf{A}$  的特征向量。虽然各个相似矩阵具有相同的特征值，但是其对应的特征向量已经变了。

### 29.2 Jordan Form

举一个例子：

- one family has  $\begin{bmatrix} 4 & 0 \\ 0 & 4 \end{bmatrix}$ ，对角矩阵的相似矩阵只有本身。 $\mathbf{M}^{-1} \underbrace{\begin{bmatrix} 4 & 0 \\ 0 & 4 \end{bmatrix}}_{4\mathbf{I}} \mathbf{M} = \begin{bmatrix} 4 & 0 \\ 0 & 4 \end{bmatrix}$
- big family include  $\begin{bmatrix} 4 & 1 \\ 0 & 4 \end{bmatrix} \Rightarrow$  约当型
- more members of family,  $\begin{bmatrix} 4 & 1 \\ 0 & 4 \end{bmatrix}, \begin{bmatrix} 5 & 1 \\ 1 & 3 \end{bmatrix}, \begin{bmatrix} 4 & 0 \\ 17 & 4 \end{bmatrix}, \dots, \begin{bmatrix} a & * \\ * & 8-a \end{bmatrix}$ ，满足条件 trace=8, det=16

下面看一看什么是约当块： $\begin{bmatrix} 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{bmatrix}, \begin{bmatrix} 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 0 \end{bmatrix}$  可总结出约当块的形式为  $\mathbf{J}_i = \begin{bmatrix} \lambda_i & 1 & 0 & 0 \\ 0 & \lambda_i & 1 & 0 \\ 0 & 0 & \lambda_i & 0 \\ \dots & \dots & \dots & \dots \end{bmatrix}$ ，特征值

上端为值为 1。every square A is similar to a Jordan matrix:

$$\mathbf{J} = \begin{bmatrix} \mathbf{J}_1 & & & \\ & \mathbf{J}_2 & & \\ \dots & \dots & \dots & \dots \\ & & & \mathbf{J}_n \end{bmatrix}$$


最好的约当矩阵就是对角矩阵。

### 30 Singular Value Decomposition

复习一下知识点。

- 一般矩阵分解  $\mathbf{A} = \mathbf{S}\mathbf{\Lambda}\mathbf{S}^{-1}$ 。
- 若矩阵为对称正定矩阵，则其特征向量一定正交，可以分解为解  $\mathbf{A} = \mathbf{Q}\mathbf{\Lambda}\mathbf{Q}^T$ 。

下面来看一下矩阵奇异值分解，涉及到两个行空间和列空间，奇异值分解就是在行空间中找一组正交基，然后经过变换，称为列空间的一组正交基。



当行空间有一组标准正交基  $v_1, v_2, \dots, v_r$ ，列空间有一组标准正交基  $u_1, u_2, \dots, u_r$ ，则用矩阵的形式表示为：

$$\mathbf{A} \begin{bmatrix} v_1 & v_2 & \cdots & v_r \end{bmatrix} = \begin{bmatrix} u_1 & u_2 & \cdots & u_r \end{bmatrix} \begin{bmatrix} \sigma_1 & 0 & 0 & 0 \\ 0 & \sigma_2 & 0 & 0 \\ & 0 & \cdots & 0 \\ 0 & 0 & 0 & \sigma_r \end{bmatrix}$$

，即也就是

$$\mathbf{A}\mathbf{V} = \mathbf{U}\Sigma, \mathbf{A} = \mathbf{U}\Sigma\mathbf{V}^{-1} = \mathbf{U}\Sigma\mathbf{V}^T$$

$$\text{so } \mathbf{A}\mathbf{A}^T = \mathbf{U}\Sigma\mathbf{V}^T\mathbf{V}\Sigma\mathbf{U}^T = \mathbf{U}\Sigma^2\mathbf{U}$$

$$\mathbf{A}^T\mathbf{A} = \mathbf{V}\Sigma\mathbf{U}^T\mathbf{U}\Sigma\mathbf{V}^T = \mathbf{V}\Sigma^2\mathbf{V}$$

下面通过一个例子计算怎么求出  $\mathbf{U}, \mathbf{V}$ , 矩阵  $\mathbf{A} = \begin{bmatrix} 4 & 4 \\ -3 & 3 \end{bmatrix}$ , 求其奇异值分解。

$$\mathbf{A}^T \mathbf{A} = \begin{bmatrix} 4 & -3 \\ 4 & 3 \end{bmatrix} \begin{bmatrix} 4 & 4 \\ -3 & 3 \end{bmatrix} = \begin{bmatrix} 25 & 7 \\ 7 & 25 \end{bmatrix}, v_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix} v_2 = \begin{bmatrix} 1 \\ -1 \end{bmatrix}$$

$$\mathbf{A}^T \mathbf{A} \begin{bmatrix} 1/\sqrt{2} \\ 1/\sqrt{2} \end{bmatrix} = 32 \begin{bmatrix} 1/\sqrt{2} \\ 1/\sqrt{2} \end{bmatrix}$$

$$\mathbf{A}^T \mathbf{A} \begin{bmatrix} 1/\sqrt{2} \\ -1/\sqrt{2} \end{bmatrix} = 18 \begin{bmatrix} 1/\sqrt{2} \\ -1/\sqrt{2} \end{bmatrix}$$

next compute  $u_i$

$$\mathbf{A} \mathbf{A}^T = \begin{bmatrix} 4 & 4 \\ -3 & 3 \end{bmatrix} \begin{bmatrix} 4 & -3 \\ 4 & 3 \end{bmatrix} = \begin{bmatrix} 32 & 0 \\ 0 & 18 \end{bmatrix}, u_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix} u_2 = \begin{bmatrix} 0 \\ 1 \end{bmatrix}$$


$$\mathbf{A} \mathbf{A}^T \begin{bmatrix} 1 \\ 0 \end{bmatrix} = 32 \begin{bmatrix} 1 \\ 0 \end{bmatrix}$$

$$\mathbf{A} \mathbf{A}^T \begin{bmatrix} 0 \\ 1 \end{bmatrix} = 18 \begin{bmatrix} 0 \\ 1 \end{bmatrix}$$

according to  $\mathbf{A} = \mathbf{U} \Sigma \mathbf{V}^T$

$$\mathbf{A} = \underbrace{\begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} \sqrt{32} & 0 \\ 0 & \sqrt{18} \end{bmatrix} \begin{bmatrix} 1/\sqrt{2} & 1/\sqrt{2} \\ 1/\sqrt{2} & -1/\sqrt{2} \end{bmatrix}}_{\text{maybe wrong}}$$

如若矩阵为非奇异, 怎么求 SVD? 下面看一个例子, 矩阵  $\mathbf{A} = \begin{bmatrix} 4 & 3 \\ 8 & 6 \end{bmatrix}$ , 可得行列空间如图:



$$\mathbf{A}^T \mathbf{A} = \begin{bmatrix} 4 & 8 \\ 3 & 6 \end{bmatrix} \begin{bmatrix} 4 & 3 \\ 8 & 6 \end{bmatrix} = \begin{bmatrix} 80 & 60 \\ 60 & 45 \end{bmatrix}, \text{rank} = 1, \lambda_1 = 0, \lambda_2 = 125$$

由于存在零空间, 所以可以根据正交性质, 构造出  $v_2, u_2$ , 得到奇异值分解为:

$$\begin{bmatrix} 4 & 3 \\ 8 & 6 \end{bmatrix} = \begin{bmatrix} 1/\sqrt{5} & 2/\sqrt{5} \\ 2/\sqrt{5} & -1/\sqrt{5} \end{bmatrix} \begin{bmatrix} \sqrt{125} & 0 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} .8 & -.6 \\ .6 & .8 \end{bmatrix}$$

## 31 linear transformation and their Matrices

看到线性两个字, 一定满足相加和数乘两个性质:

$$T(\mathbf{V} + \mathbf{W}) = T(\mathbf{V}) + T(\mathbf{W})$$

$$T(c\mathbf{V}) = cT(\mathbf{V})$$

矩阵背后就是线性变换, 下面看两个例子:

**Example 1**, 投影变换。




图 8: Projection

**Example 2** Rotation by  $45^\circ$




图 9: 旋转 $45^\circ$

**Example 3** Matrix

$$T(v) = \mathbf{A}v$$




图 10: 翻转

上图中的小房子，通过矩阵  $\mathbf{A}$  作用后，得到翻转的效果，可以发现，线性变换其实就是寻找背后的其作用的矩阵。  
可以验证，此变换符合线性变换的两个性质：① $T(v + w) = \mathbf{A}(v + w) = \mathbf{A}v + \mathbf{A}w$

下面将进一步讲解什么是线性变换。

- start  $T : \mathbf{R}^3 \rightarrow \mathbf{R}^2$ 。

**Example**

$$\underbrace{T(v)}_{\text{output in } \mathbf{R}^2} = \mathbf{A} \underbrace{v}_{\text{input in } \mathbf{R}^3}$$

every linear transformation is associated with a matrix。

information needed to know  $T(v)$  for all inputs, if know  $T(v_1), T(v_2), \dots, T(v_n)$  for any inputs basis  $v_1, v_2, \dots, v_n$ . and then we know  $T(v)$ , because

$$every v = c_1 v_1 + c_2 v_2 + \dots + c_n v_n$$

and then:

$$T(v) = c_1 T(v_1) + c_2 T(v_2) + \dots + c_n T(v_n)$$

- coordinates  $(c_1, c_2, \dots, c_n)$  come from a basis,  $v = c_1 v_1 + c_2 v_2 + \dots + c_n v_n$ .

$$v = \begin{bmatrix} 3 \\ 2 \\ 4 \end{bmatrix} = 3 \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix} + 2 \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix} + 4 \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}$$


我们经常看到的坐标，其实代表一个线性组合。Amazing 🧐。

- Construct matrix **A** that represents linear transformation T.

$T: \mathbf{R}^n \rightarrow \mathbf{R}^m$ .

choose basis  $v_1, v_2, \dots, v_n$  for inputs in  $\mathbf{R}^n$ .

choose basis  $w_1, w_2, \dots, w_m$  for outputs in  $\mathbf{R}^m$ . 举一个投影例子求矩阵 **A**。



所以得到:

$$\left. \begin{aligned} v &= c_1 v_1 + c_2 v_2, (c_1, c_2) \\ T(v) &= c_1 v_1, (c_1, 0) \end{aligned} \right\} \Rightarrow \underbrace{\begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix}}_{\mathbf{A}} = \underbrace{\begin{bmatrix} c_1 \\ c_2 \end{bmatrix}}_{input} \underbrace{\begin{bmatrix} c_1 \\ 0 \end{bmatrix}}_{output}$$

如果特征向量作为基，则会得到一个对角矩阵。

- rule to find **A**, Given basis  $v_1 - v_n, w_1 - w_m$ .

1st column of **A**,  $T(v_1) = a_{11}w_1 + a_{21}w_2 + \dots + a_{m1}w_m$

2nd column of **A**,  $T(v_2) = a_{12}w_1 + a_{22}w_2 + \dots + a_{m2}w_m$


...

$\mathbf{A}(\text{input coordinates}) = (\text{output coordinates})$

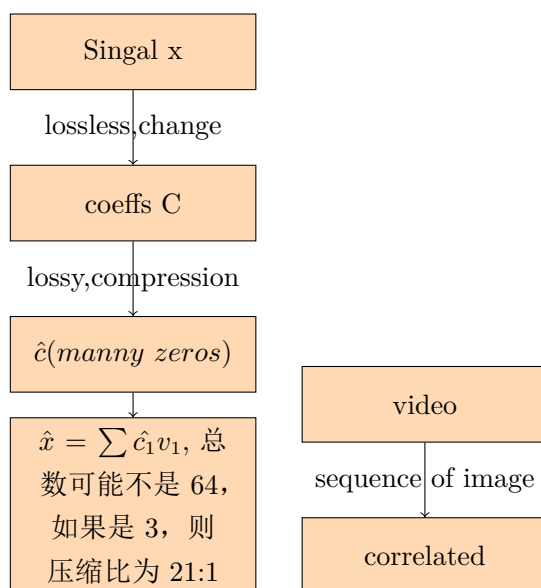
线性变换也可以运用到微分上来。  $T = \frac{d}{dx}$ , 可以叫做微分变换 😊。

$$\left. \begin{aligned} input & c_1 + c_2 x + c_3 x^2, basis \ 1 \ x \ x^2 \\ output & c_2 + 2c_3 x, basis \ 1 \ x \end{aligned} \right\} \Rightarrow \begin{bmatrix} 0 & 1 & 0 \\ 0 & 0 & 2 \end{bmatrix} \begin{bmatrix} c_1 \\ c_2 \\ c_3 \end{bmatrix} = \begin{bmatrix} c_2 \\ 2c_3 \end{bmatrix}$$

## 32 change of Basis, Image compression



$$\begin{array}{c}
 \text{standard basis} \\
 \begin{bmatrix} 1 \\ 0 \\ \dots \\ 0 \end{bmatrix} \begin{bmatrix} 0 \\ 1 \\ \dots \\ 0 \end{bmatrix} \dots \begin{bmatrix} 0 \\ 0 \\ \dots \\ 1 \end{bmatrix}
 \end{array}
 \begin{array}{c}
 \text{better basis} \\
 \begin{bmatrix} 1 \\ 1 \\ 1 \\ 1 \\ 1 \\ 1 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \\ 1 \\ -1 \\ -1 \\ -1 \end{bmatrix} \begin{bmatrix} 1 \\ -1 \\ -1 \\ 1 \\ 1 \\ -1 \end{bmatrix}
 \end{array}
 \begin{array}{c}
 \text{Fourier} \\
 \begin{bmatrix} 1 & 1 & 1 & \dots & 1 \\ 1 & w & w^2 & \dots & w^{n-1} \\ 1 & w^2 & w^4 & \dots & w^{2(n-1)} \\ \dots & \dots & \dots & \ddots & \dots \\ 1 & w^{n-1} & w^{2(n-1)} & \dots & w^{(n-1)(n-1)} \end{bmatrix}
 \end{array}$$



假设取 8 个像素点, 在标准基与小波基之间的变换如下。

$$\begin{bmatrix} P_1 \\ P_2 \\ P_3 \\ P_4 \\ P_5 \\ P_6 \\ P_7 \\ P_8 \end{bmatrix} = c_1 \begin{bmatrix} 1 \\ 1 \\ 1 \\ 1 \\ 1 \\ 1 \\ 1 \\ 1 \end{bmatrix} + c_2 \begin{bmatrix} 1 \\ 1 \\ 1 \\ 1 \\ -1 \\ -1 \\ -1 \\ -1 \end{bmatrix} + c_3 \begin{bmatrix} 1 \\ 1 \\ -1 \\ -1 \\ 0 \\ 0 \\ 0 \\ 0 \end{bmatrix} + c_4 \begin{bmatrix} 1 \\ 0 \\ 0 \\ 0 \\ 1 \\ 1 \\ 1 \\ 1 \end{bmatrix} + c_5 \begin{bmatrix} 1 \\ -1 \\ 0 \\ 0 \\ 0 \\ 0 \\ 0 \\ 0 \end{bmatrix} + c_6 \begin{bmatrix} 0 \\ 0 \\ 1 \\ -1 \\ 0 \\ 0 \\ 0 \\ 0 \end{bmatrix} + c_7 \begin{bmatrix} 0 \\ 0 \\ 0 \\ 0 \\ 1 \\ -1 \\ 0 \\ 0 \end{bmatrix} + c_8 \begin{bmatrix} 0 \\ 0 \\ 0 \\ 0 \\ 0 \\ 0 \\ 1 \\ -1 \end{bmatrix}, \mathbf{P} = \mathbf{W}c, c = \mathbf{W}^{-1}\mathbf{P}$$

good basis

1. Fast, FFT, FWT



$$2. \text{ Few is enough, } \mathbf{P} = \begin{bmatrix} w_1 & w_2 & \dots & w_8 \end{bmatrix} \begin{bmatrix} c_1 \\ c_2 \\ \dots \\ c_8 \end{bmatrix}$$

下面讲一下线性变换的一点作用。

To linear transform

- with respect to  $v_1, v_2, \dots, v_8$ , it has matrix  $\mathbf{A}$ . with respect to  $w_1, w_2, \dots, w_8$ , it has matrix  $\mathbf{B}$ . 则  $\mathbf{A}$  is similar to  $\mathbf{B}$ .  $\mathbf{B} = \mathbf{M}^{-1} \mathbf{A} \mathbf{M}$